

Projet IF36

Analyse des données olympiques

(1896-2024)

Dataset Kaggle

8 500 Athlètes

30 Variables

Équipe

Data Squad

Objectif Principal

Extraire des tendances sur la **performance**, la **morphologie**, les **pays** et le **genre**.



Présentation du dataset

Profil Athlète

age, gender, height, weight
Caractéristiques physiques

Performance

sport, event, result, medal
Mesurer le niveau sportif

Expérience & Nat.

total_olympics, nationality
Impact de l'expérience et pays

Contexte Olympique

year, games_type, host_city
Évolution et effet pays hôte

SYSTÈME DE DONNÉES

Une structure multidimensionnelle permettant de croiser **morphologie**, **performance** et **temporalité**.

Problématique

MORPHOLOGIE

Impact sur performance

GÉOPOLITIQUE

Pays dominants

ÉQUITÉ

Genre & représentativité

TEMPORALITÉ

Évolution des JO

Méthode d'analyse

1. Question / Hypothèse

Exemple : “L’IMC influence-t-il la performance sportive ?”

On commence par une intuition ou une problématique métier.

2. Graphique adapté

- Bar chart: comparer
- Scatter: corrélation
- Heatmap: proportions
- Line chart: évolution

3. Analyser les résultats


On interprète :

- tendances & corrélations
- anomalies
- limites du dataset

4. Approfondir

Processus itératif :

- zoom & nouveau graphe
- analyse plus fine



**Le processus
devient *itératif*.**

Exploration initiale : matrice de corrélation

POURQUOI CE GRAPHIQUE ?

Utiliser une matrice de corrélation de Pearson pour détecter d'éventuelles relations linéaires entre les variables du dataset.

CE QU'ON OBSERVE


La majorité des corrélations sont très faibles ou nulles (≈ 0)

Les seules corrélations fortes sont logiques / redondantes :

- nationality $\leftrightarrow$ country_name
- country_total_gold $\leftrightarrow$ country_total_medals
- total_medals_won $\leftrightarrow$ gold_medals

Aucune corrélation globale forte n'émerge pour expliquer la performance

Matrice de Corrélation des Variables du Dataset (Triangle Inférieur)





Pays avec le plus de médailles d'or

Analyse de la dominance

- USA : dominant très largement le classement mondial.
- Europe : très présente avec de multiples nations dans le top 15.
- Facteurs clés :
 - Investissement massif dans le sport de haut niveau
 - Infrastructures et centres d'entraînement
 - Détection précoce des talents
 - Culture sportive nationale

Le **volume de médailles** reflète l'investissement structurel des nations dans le sport de haut niveau.



Morphologie vs Performance

POURQUOI CE GRAPHIQUE ?

Mesurer l'intensité de la corrélation entre l'IMC and la performance par discipline via le coefficient de Pearson.


CE QU'ON OBSERVE

Certaines épreuves présentent une corrélation modérée à forte (*jusqu'à 0.57*)

Les corrélations les plus marquées apparaissent dans :

- Gymnastics - Parallel Bars
- Boxing - Lightweight
- Swimming - 400m Freestyle

Top 10 des corrélations IMC / Performance par épreuve




L'impact de la morphologie devient plus visible à l'échelle des épreuves, et non du sport global.

Morphologie vs Performance

Focus sur la gymnastique et la Natation


GYMNASTIQUE : CORRÉLATION POSITIVE

- Droite de tendance montante
- IMC plus élevé → score légèrement supérieur
- Une morphologie spécifique semble favoriser la performance



SWIMMING : CORRÉLATION NÉGATIVE

- Droite de tendance descendante
- En natation, moins de secondes = meilleure performance
- Un IMC plus élevé est associé à un meilleur chrono



Conclusion : Une même variable morphologique (IMC) peut avoir des effets opposés selon les exigences biomécaniques de l'épreuve.


Nombre d'athlètes par discipline

Vue d'ensemble des sports

Le premier graphique illustre la distribution pour l'ensemble des disciplines.

- Couvre tous les sports représentés.
- Les écarts de participation ne sont pas significatifs
- Pas très lisible


Répartition des disciplines sportives par nombre d'athlètes



Zoom sur le Top 5

Une analyse plus fine des disciplines les plus denses.

- Sélection des 5 disciplines majeures.
- L'écart entre ces disciplines est inférieur à 20 athlètes.
- Pas les "grands" sports auxquels on pense



Performance aux éditions a domicile

Pourquoi cette question ?


L'influence de l'accueil des Jeux sur la performance athlétique.

- Existe-t-il une surperformance à domicile ?
- Observer le boost réel des résultats.

Observations clés

Une tendance claire se dégage des données historiques.

- Augmentation moyenne de **30 %** des médailles.
- Constaté pour tous les pays hôtes.



Conclusion : L'organisation des Jeux Olympiques génère un avantage compétitif mesurable et systématique.

Spécialisation de la taille

Basketball


Évolution de la taille des athlètes :

- Tendance à la hausse
- Gain moyen de 5 cm
- Pic fréquent au-dessus de 2 mètres

Gymnastique artistique


Évolution inverse de la taille:

- Tendance à la baisse
- Perte moyenne de 5 cm




Conclusion : La spécialisation physique s'accroît selon les exigences de chaque discipline.

Application Shiny : un explorateur interactif



Onglet 1 - Nuage taille × poids

- Filtres : discipline, saison, genre
- Morphologie caractérise la discipline, pas la médaille (ex: Basketball)




Onglet 2 - Distribution de l'IMC

- Comparaison interactive multiculturelle
- Haltérophilie (IMC ≈ 33) vs Gymnastique (≈ 21)

Valeur ajoutée : l'interactivité permet de répondre aux questions spécifiques du lecteur.

Power BI : un peu plus d'interactivité

Efficacité des délégations olympiques



Avantages vs R

- Interactivité : un clic recalculé tout
- Carte mondiale clé en main
- Tableau de bord unifié sans code

Limites vs R

- .pbix binaire opaque vs un .rmd reproductible
- Statistiques avancées limitées (corrélations, régressions)
- Géocodage imparfait (URSS) / filtre sport/année instable

Limites du dataset

Essentiel pour démontrer un esprit critique et une maturité analytique.

Données synthétiques

Plusieurs variables sont générées aléatoirement :

l'âge (≈ 28 ans dans tous les sports), les médailles, le mois de naissance, les records.

Beaucoup de corrélations ressortent donc nulles.

Échantillon équilibré

Environ 250 à 280 athlètes par discipline :

le jeu n'est pas exhaustif mais calibré. Il ne reflète pas les effectifs réels des délégations olympiques.

Structure & unités

1 ligne = 1 athlète (aucun suivi de carrière).

La colonne `result_value` mélange secondes, mètres, points et kg : non comparable d'un sport à l'autre.

CONCLUSION
