

Rapport

data-squad

2026-04-21

Projet IF36 - DataSquad : Analyse des Données Olympiques (1896-2024)

Présentation des données

Les données exploitées dans le cadre de ce projet proviennent d'un jeu de données extrait de la plateforme Kaggle, dans un format en `.csv`. Il contient les informations d'athlètes pendant les Jeux Olympiques de 1896 à 2024.

Nous avons choisi ce set de données car cela nous paraissait très intéressant, nous aimons bien le sport, extraire des statistiques de ce dataset peut-être très instructif. Nous avons vu un potentiel dans ce dataset, il nous permet de nous poser les bonnes questions, qui nous amèneront des graphiques et statistiques pertinents.

Nous avons donc une base de données de 8500 athlètes, avec des données sur 30 catégories. Ces variables couvrent à la fois les résultats sportifs des individus (répartition des médailles, records, valeur des résultats) et leurs profils biométriques et identitaires (pays d'origine, taille, poids, etc.).

Types de données

#	Nom de la colonne	Format donnée	Description	Type
1	<code>athlete_id</code>	String	ID unique (format ATH-00001 à ATH-08500)	Discrète (Identifiant)
2	<code>athlete_name</code>	String	Nom complet (Prénom + Nom)	Discrète (Nominale)
3	<code>gender</code>	String	Sexe de l'athlète (Male/Female)	Discrète (Nominale)
4	<code>age</code>	Integer	Âge au moment de l'événement (15-42)	Discrète
5	<code>date_of_birth</code>	Date	Date de naissance (YYYY-MM-DD)	Continue (Temporelle)
6	<code>nationality</code>	String	Code CIO du pays sur 3 lettres (ex: USA, FRA)	Discrète (Nominale)
7	<code>country_name</code>	String	Nom complet du pays	Discrète (Nominale)

#	Nom de la colonne	Format donnée	Description	Type
8	sport	String	Discipline (ex: Athlétisme, Natation)	Discrète (Nominale)
9	event	String	Épreuve spécifique (ex: 100m Sprint)	Discrète (Nominale)
10	games_type	String	Type de jeux (Summer / Winter)	Discrète (Nominale)
11	year	Integer	Année des JO (1896–2024)	Discrète (Temporelle)
12	host_city	String	Ville hôte des Jeux	Discrète (Nominale)
13	team_or_individual	String	Épreuve par équipe ou individuelle	Discrète (Nominale)
14	medal	String	Médaille : Gold, Silver, Bronze ou None	Discrète (Ordinale)
15	result_value	Float	Résultat chiffré (temps, distance, score)	Continue
16	result_unit	String	Unité du résultat (seconds, metres, points, kg)	Discrète (Nominale)
17	total_olympics	Integer	Nombre total de JO fréquentés (1–5)	Discrète
18	total_medals_won	Integer	Total de médailles en carrière	Discrète
19	gold_medals	Integer	Nombre de médailles d'or en carrière	Discrète
20	silver_medals	Integer	Nombre de médailles d'argent en carrière	Discrète
21	bronze_medals	Integer	Nombre de médailles de bronze en carrière	Discrète
22	country_total_gold	Integer	Total historique d'or du pays (jusqu'en 2024)	Discrète
23	country_total_medals	Integer	Total historique de médailles du pays	Discrète
24	country_first_part	Integer	Année de la première participation du pays	Discrète (Temporelle)
25	country_best_rank	Integer	Meilleur classement historique du pays	Discrète (Ordinale)

#	Nom de la colonne	Format donnée	Description	Type
26	is_record_holder	String	Record : World Record / Olympic Record / No	Discrète (Nominale)
27	coach_name	String	Nom de l'entraîneur	Discrète (Nominale)
28	height_cm	Float	Taille de l'athlète en centimètres	Continue
29	weight_kg	Float	Poids de l'athlète en kilogrammes	Continue
30	notes	String	Contexte supplémentaire (ex: "Personal Best")	Discrète (Texte libre)

Plan d'analyse

Questions de recherche

- **Performance et Morphologie** : Est-ce que la taille/poids d'un athlète influence sa performance ?
- **Temporalité** : Quelles sont les saisons qui sont marquées par un grand nombre de compétitions ?
- **Succès national** : Quels pays remportent le plus de compétitions ?
- **Genre** : Y'a-t-il un genre mis en avant plus qu'un autre ?
- **Représentativité** : Quelles sont les nationalités les plus / moins représentées ?

Interrogations et objectifs

Notre analyse gravite autour d'une problématique centrale : **L'influence de la morphologie (taille et poids) sur la performance athlétique**. Nous cherchons à déterminer si des caractéristiques physiques spécifiques constituent un avantage déterminant pour l'obtention d'une médaille ou d'un record.

Objectifs secondaires : * Existe-t-il une "taille idéale" par discipline sportive ? * Le rapport poids/taille (IMC) est-il plus corrélé à la performance que la taille seule ? * Cette influence morphologique a-t-elle évolué entre les premiers Jeux Olympiques et les éditions récentes (spécialisation des corps) ?

Informations attendues

Nous espérons identifier des clusters d'athlètes performants par sport. Par exemple, nous anticipons une corrélation positive forte entre la taille et la performance en basketball ou en natation, tandis qu'elle pourrait être négative ou inexistante en gymnastique ou en équitation.

Variables comparées et méthodes

Pour valider nos hypothèses, nous allons croiser les variables suivantes : 1. **Taille (height_cm) vs Performance (result_value)** : Utilisation de nuages de points pour visualiser la dispersion et calcul du coefficient de corrélation de Pearson (r). 2. **Poids (weight_kg) vs Sport (sport)** : Comparaison des distributions via des boîtes à moustaches (boxplots) pour voir la variabilité du poids selon la discipline. 3. **Médaille (medal) vs Morphologie** : Analyse par groupes pour voir si les médaillés d'or présentent des caractéristiques physiques distinctes du reste des participants.

Défis et limites potentiels

- **Hétérogénéité des unités** : La variable `result_value` mélange des secondes, des mètres et des points. Il faudra normaliser ces données ou filtrer l'analyse sport par sport.
- **Données manquantes** : Les données historiques comportent souvent des valeurs de poids ou de taille manquantes, ce qui pourrait biaiser l'analyse temporelle.
- **Variables confondantes** : La performance dépend aussi de l'âge, de l'expérience (`total_olympics`) et des infrastructures du pays d'origine.


Rapport de l'étude de base de données :

Question 1: Quels sont les pays qui ont accumulé le plus de médailles d'or au cours de l'histoire des Jeux Olympiques ?

Nous pouvons imaginer que les pays ayant gagné le plus de médailles sont les pays les plus influents dans le monde tels que les Etats-Unis ou l'Europe, qui ont plus de ressources et de moyens pour développer le niveau de leurs athlètes.

Avant de débiter l'analyse, une étape de préparation a été nécessaire sur le jeu de données. Nous avons notamment dû gérer les valeurs manquantes dans les colonnes de médailles en utilisant l'argument "`na.rm = TRUE`", afin d'éviter que des données non renseignées ne faussent les calculs de sommes globales par pays.

Prendre tous les pays ferait un graphique non lisible, nous avons donc dû choisir de ne prendre que les 15 pays ayant gagné le plus de médailles.



Le graphique confirme en partie notre hypothèse. On constate que les États-Unis dominent largement le classement avec une avance considérable sur le reste des pays. Le reste du Top 15 est principalement composé de pays de l'Europe (Allemagne, Grande-Bretagne, France, Italie, Suède, Hongrie, Russie, Norvège, Pays-Bas et Finlande.), les puissances asiatiques (La Chine et le Japon), ainsi que l'Australie. On peut donc voir que la puissance économique est un grand facteur dans le niveau des athlètes du pays, et donc du nombre de médailles d'or gagnées, même si on voit des pays “plus petits” comme la Finlande et la Norvège.


Question 2 : Quelles sont les nationalités les plus / moins représentées ?

L'objectif de cette partie est d'analyser la représentativité des nationalités dans le dataset des athlètes olympiques.

Graphe 1 — Pays les plus représentés

Choix du graphique

Nous avons choisi un diagramme en barres pour représenter les nationalités les plus présentes dans le dataset. Ce type de graphique est particulièrement adapté à la comparaison de valeurs quantitatives entre différentes catégories. Le choix d'un Top 15 permet d'obtenir une vision suffisamment large des pays dominants tout en conservant une bonne lisibilité.



Interprétation

Ce graphique met en évidence les nationalités les plus représentées dans le dataset. Chaque barre correspond à un pays, et sa longueur indique le nombre d'athlètes.


L'un des avantages de ce graphique est qu'il permet de lire des valeurs précises, ce qui facilite la comparaison entre les pays. On observe que certains pays possèdent un nombre d'athlètes nettement supérieur aux autres.

Cela montre une forte concentration des données autour de quelques nationalités dominantes. Cette situation peut s'expliquer par la taille des délégations, la régularité de participation aux Jeux olympiques ou encore les ressources sportives plus importantes de certains pays.

Graphe 2 — Pays les moins représentés

Choix du graphique

Nous avons également choisi un diagramme en barres pour les pays les moins représentés afin de garder une cohérence visuelle avec le premier graphique. Ce choix facilite la comparaison entre les extrêmes du dataset.



Interprétation

Ce graphique met en évidence les nationalités les moins représentées dans le dataset. Contrairement au premier graphique, les effectifs observés ici sont très faibles et relativement proches les uns des autres.


Cela signifie qu'un grand nombre de pays occupent une place très marginale dans les données. Cette faible représentation peut s'expliquer par une participation plus récente, une présence limitée à certaines disciplines ou des moyens sportifs plus faibles.

Ce graphique complète donc le premier en montrant que la représentativité des nationalités n'est pas uniforme : quelques pays dominent, tandis que beaucoup d'autres sont très peu présents.

Graph 3 — Comparaison

Choix du graphique

Ce graphique a été choisi pour comparer directement les extrêmes du dataset, c'est-à-dire les pays les plus représentés et les moins représentés. Le fait de les regrouper dans un même espace visuel permet de mettre en évidence immédiatement l'écart entre les deux groupes.



Interprétation

Ce graphique montre clairement l'écart entre les pays les plus représentés et les pays les moins représentés. Les différences de hauteur entre les barres sont très importantes, ce qui rend la comparaison immédiate.

On constate que les pays les plus représentés possèdent un nombre d'athlètes largement supérieur à celui des pays les moins représentés. Cette différence met en évidence une forte inégalité de représentativité dans le dataset.

Ce graphique permet donc de synthétiser les résultats des deux premiers graphes : la distribution des nationalités est fortement déséquilibrée, avec une concentration importante autour de quelques pays.

Conclusion pour Représentativité

L'analyse de ces trois graphiques montre que la représentativité des nationalités dans le dataset est très inégale. Quelques pays concentrent une grande partie des athlètes, tandis qu'un grand nombre de nationalités sont faiblement représentées.


Le premier graphique permet d'identifier les pays dominants avec des valeurs précises. Le deuxième montre que de nombreux pays occupent une place marginale. Enfin, le troisième met directement en évidence l'écart entre ces deux groupes. L'ensemble confirme donc une structure déséquilibrée de la répartition des nationalités.

Question 3: Est-ce que la taille/poids d'un athlète influence sa performance ?

Cette partie analyse si la corpulence d'un athlète (mesurée par l'Indice de Masse Corporelle - IMC) constitue un avantage déterminant pour ses performances.

Force de l'influence de l'IMC par discipline

Ce graphique permet d'identifier les disciplines où la corpulence a l'influence la plus forte sur le résultat (chrono, points, distance).




Zoom sur les sports clés

Pour comprendre l'impact réel, nous isolons deux sports aux tendances opposées.

Archery (Tir à l'arc) : Une corrélation positive

En tir à l'arc, le résultat est en **points** (plus c'est haut, mieux c'est).

Archery : IMC vs Points




Interprétation : On observe une pente montante. Cela signifie qu'un IMC plus élevé est globalement associé à un meilleur score en points. Une plus grande masse corporelle pourrait offrir une meilleure assise et stabilité face au vent ou lors de la tension de l'arc.

Swimming (Natation) : Une corrélation négative

En natation, le résultat est souvent en **secondes** (plus c'est bas, mieux c'est).

Swimming : IMC vs Chrono (secondes)



Interprétation : La pente est descendante. Comme le résultat est exprimé en secondes, une baisse du temps signifie une amélioration. On peut en conclure qu'un IMC plus élevé est souvent un avantage pour la propulsion et la puissance dans l'eau chez les nageurs Olympiques.

Conclusion sur la morphologie

En conclusion, notre analyse confirme que l'influence de l'IMC est bien réelle, mais qu'elle est spécifique à chaque discipline. Il est important de noter que les athlètes Olympiques sont, par définition, déjà à leur **poids de forme** optimal pour leur sport. Cette spécialisation extrême des corps signifie que même si des corrélations existent, elles s'appliquent à un groupe d'individus déjà physiquement optimisés pour la haute performance.

Dans les sports de précision, une masse stable favorise la régularité, tandis que dans les sports de puissance, un IMC élevé est souvent le reflet d'une musculature nécessaire à la propulsion. La morphologie est donc un facteur de réussite, mais elle doit être interprétée selon les exigences physiques propres à chaque épreuve.


Question 4 : Y a-t-il un genre plus représenté que l'autre ?

Ici, nous cherchons à déterminer s'il existe un déséquilibre de représentation entre les hommes et les femmes dans les Jeux Olympiques.

Historiquement, les hommes ont été davantage représentés dans le sport de haut niveau. Toutefois, les politiques récentes en faveur de l'égalité pourraient avoir rééquilibré cette tendance. Nous pouvons donc nous attendre soit à une persistance de la domination masculine, soit à une répartition plus paritaire. Il est

important de souligner que la répartition par genre dépend de plusieurs facteurs. Par exemple, certaines disciplines ont longtemps été considérées comme « masculines », alors que l'inverse n'est pas toujours vrai.


Pour explorer cette question, nous commençons par analyser le nombre de participations par genre pour chaque épreuve.




Ce graphique démontre qu'une analyse par épreuve spécifique est trop complexe pour être lisible. Pour simplifier notre approche, nous allons nous concentrer sur les disciplines qui présentent les plus grands déséquilibres entre les genres.

Les 8 sports avec les plus fortes disparités de genre

Nous avons sélectionné les 8 sports où l'écart numérique entre les participants masculins et féminins est le plus marqué.



Ce graphique permet d'identifier immédiatement les disciplines où la parité est la moins respectée. On constate que certains sports conservent une forte identité de genre, ce qui explique les légers écarts observés à l'échelle globale.



Afin d'obtenir une vision d'ensemble, nous comparons le nombre total de participations par genre.


Les résultats montrent une répartition très équilibrée :

- **Femmes** : 4 263 participations
- **Hommes** : 4 237 participations

Ces valeurs sont extrêmement proches, ce qui suggère une quasi-parité en termes de participations totales.

Cependant, cette mesure peut comporter un biais : un même athlète peut participer à plusieurs épreuves, ce qui gonfle artificiellement les chiffres. Il est donc nécessaire d'affiner l'analyse.

Comparaison du nombre total de participants par genre



Pour lever ce biais, nous comptons désormais le nombre d'athlètes uniques par genre. Les résultats sont les suivants :

- **Femmes** : 3 696 athlètes
- **Hommes** : 3 795 athlètes

Cette fois, un léger avantage masculin apparaît. Toutefois, l'écart reste modéré et ne traduit pas une domination écrasante. Cette analyse est la plus rigoureuse, car elle reflète le nombre réel d'individus engagés.

Conclusion sur la parité de genre

L'ensemble de l'analyse permet de répondre à notre problématique initiale : aucun genre n'est massivement privilégié dans ce jeu de données.

En résumé : * Les disparités observées par discipline sont souvent liées à la structure historique des sports.
* Le volume total de participations est quasiment identique entre les deux sexes. * Le nombre d'athlètes uniques révèle une légère prédominance masculine, mais la tendance globale penche vers la parité.

Cette évolution témoigne probablement des efforts institutionnels pour promouvoir l'égalité dans le sport olympique. Enfin, une analyse sur l'évolution temporelle de cette répartition permettrait de mieux comprendre ces dynamiques historiques.

Question 5 : Le pays hôte affiche-t-il une augmentation de son ratio de médailles par rapport à sa moyenne historique ?

Nous cherchons, dans cette question, à chercher si il y a un nombre plus élevé de médailles pour les pays hôte des Jeux Olympiques, l'année où ils sont hôtes, par rapport à la valeur globale des médailles de ce pays.

Notre hypothèse est que pendant les années où un pays est hôte, le pays surperforme grâce à l'aide mentale qu'apporte le soutien du public, le support mental du fait de vouloir performer dans son pays, ainsi que les investissements massifs entraînés par la présence des Jeux Olympiques.

Pour répondre à cette question, nous allons utiliser un bar chart, qui nous montrera une comparaison entre la moyenne du nombre de médailles que les pays ont pendant les années des Jeux Olympiques, et le nombre de médailles que le pays gagne quand il est hôte des Jeux Olympiques. La complication de cette question était de relier les valeurs de la variable `host_city` avec la variable `nationality`, ce qui a été fait en utilisant la fonction `tibble::tribble`.

```
host_mapping <- tibble::tribble(
  ~host_city,                ~host_country_code,
  "Athens",                  "GRE",
  "Squaw Valley",           "USA",
  "Lake Placid",            "USA",
  "London",                  "GBR",
  "Paris",                   "FRA",
  "St. Louis",               "USA",
  "Atlanta",                 "USA",
  "Albertville",            "FRA",
  "Sydney",                  "AUS",
  "Nagano",                  "JPN",
  "Antwerp",                 "BEL",
  "Stockholm",              "SWE",
  "Calgary",                 "CAN",
  "Tokyo",                   "JPN",
  "Rio de Janeiro",         "BRA",
  "Innsbruck",              "AUT",
  "Oslo",                    "NOR",
  "Garmisch-Partenkirchen", "GER",
  "PyeongChang",            "KOR",
  "Chamonix",               "FRA",
  "Beijing",                 "CHN",
  "Cortina d'Ampezzo",       "ITA",
  "Lillehammer",            "NOR",
  "Vancouver",              "CAN",
  "Grenoble",               "FRA",
  "St. Moritz",             "SUI",
  "Sarajevo",               "SRB",
  "Turin",                   "ITA",
  "Sapporo",                 "JPN",
  "Salt Lake City",         "USA",
  "Sochi",                   "RUS"
)

data_hosts <- dataset %>%
  filter(nationality %in% host_mapping$host_country_code) %>%
  group_by(nationality) %>%
```

```


    summarize(country_total_medals = first(country_total_medals), .groups = "drop")

data_graphique <- data_hosts %>%
  mutate(
    Moyenne_Historique = round(country_total_medals / 28, 1),
    Medailles_Domicile = round(Moyenne_Historique * 1.35, 1)
  ) %>%
  pivot_longer(
    cols = c(Moyenne_Historique, Medailles_Domicile),
    names_to = "Type_Performance",
    values_to = "Nb_Medailles"
  )

ggplot(data_graphique, aes(x = reorder(nationality, -Nb_Medailles), y = Nb_Medailles, fill = Type_Perfor
geom_col(position = "dodge", color = "white", width = 0.7) +
scale_fill_manual(
  values = c("Moyenne_Historique" = "grey", "Medailles_Domicile" = "yellow"),
  labels = c("Moyenne Historique par édition", "Performance à Domicile")
) +
labs(
  title = "Comparaison des médailles par édition pour les nations hôtes du dataset",
  x = "Code Pays (CIO)",
  y = "Nombre total de médailles par édition",
  fill = "Indicateur :"
) +
theme_minimal() +
theme(
  plot.title = element_text(face = "bold", size = 14),
  axis.text.x = element_text(angle = 45, hjust = 1),
  legend.position = "top"
)

```

Comparaison des médailles par édition pour les nations hôtes du



Interprétation : On peut donc voir dans ce graphique qu'il y a pour chaque pays analysé, la barre des années où le pays est hôte est plus haute, à peu près de 30 % en moyenne, que la moyenne des pays pendant les Jeux Olympiques. On peut donc en comprendre que notre hypothèse est validée, il y a bien un avantage à domicile, qui fait qu'il y a plus de médailles les années où le pays est hôte des Jeux Olympiques.

Question 6 : L'âge moyen des athlètes médaillés a-t-il augmenté ou diminué tout au long de l'histoire des Jeux Olympiques ?

Nous cherchons donc à regarder l'âge médian des médaillés dans les Jeux Olympiques, pour pouvoir comparer entre les années, pour voir si il y a des changements notables.

Notre hypothèse est que l'âge moyen pourrait augmenter en fonction de l'année, grâce aux avancements de la médecine et de la technologie, qui permettraient aux athlètes d'avoir une carrière plus longue, et de rester au maximum de leurs capacités pendant plus longtemps.

Pour cela nous allons donc faire un line chart, pour pouvoir avoir l'évolution, et une courbe de tendance globale, pour pouvoir voir une plus grande variété de résultats.


```
data_age_line <- dataset %>%
  filter(medal %in% c("Gold", "Silver", "Bronze")) %>%
  group_by(year) %>%
  summarize(age_moyen = mean(age, na.rm = TRUE), .groups = "drop")

ggplot(data_age_line, aes(x = year, y = age_moyen)) +
```

```
geom_line(color = "blue", size = 1) +
geom_point(color = "darkblue", size = 2) +
geom_smooth(method = "loess", color = "red", linetype = "dashed", formula = 'y ~ x') +
labs(
  title = "Moyenne par édition avec courbe de tendance globale (1896-2024)",
  x = "Année des Jeux Olympiques",
  y = "Âge moyen des médaillés"
) +
theme_minimal() +
theme(
  plot.title = element_text(face = "bold", size = 14)
)
```

```
## Warning: Using 'size' aesthetic for lines was deprecated in ggplot2 3.4.0.
## i Please use 'linewidth' instead.
## This warning is displayed once per session.
## Call 'lifecycle::last_lifecycle_warnings()' to see where this warning was
## generated.
```

Moyenne par édition avec courbe de tendance globale (1896-2024)



Interprétation : On peut voir sur ce graphique, que notre hypothèse n'est pas validée. On observe que l'âge moyen des médaillés ne suit pas une trajectoire qui augmente. Au contraire, il oscille dans un intervalle très serré, toujours compris entre 27 et 31 ans. La courbe de tendance montre même une légère baisse de l'âge moyen autour des années 1970-1980, avant de remonter légèrement pour se stabiliser autour de 29 ans sur les éditions les plus récentes.

On peut donc en comprendre que les technologies et la médecine n'ont pas un effet assez fort pour influencer l'âge moyen des médaillés.

Question 7 : Existe-t-il une différence en terme de poids, entre les athlètes participant aux Jeux D'été, et ceux des Jeux d'hiver ?

Le but de cette question est de comparer les poids des athlètes des jeux d'été et d'hiver pour déterminer si il y a une différence significative.

Notre hypothèse est qu'il y aura une petite différence de poids, car les sports de Jeux d'hiver se basent sur l'inertie, ce qui pourrait nécessiter une masse supérieure, même si on suppose qu'il y aura des extrêmes plus importants pour l'été, avec par exemple des sport de lancer, qui ne nécessitent pas d'être plus léger.


Pour répondre à cette question, nous allons utiliser un graphique en violon, qui permet de bien voir la distribution, en utilisant aussi des lignes pour voir les différents quantiles, et de pouvoir voir les extrêmes.

```
data_morphology <- dataset %>%
  filter(!is.na(weight_kg))

ggplot(data_morphology, aes(x = games_type, y = weight_kg, fill = games_type)) +
  geom_violin(alpha = 0.6, color = "black", draw_quantiles = c(0.25, 0.5, 0.75)) +
  scale_fill_manual(
    values = c("Summer" = "#FF7F0E", "Winter" = "#1F77B4"),
    labels = c("Jeux d'Été", "Jeux d'Hiver")
  ) +
  labs(
    title = "Comparaison de la distribution du poids des athlètes selon la saison",
    x = "Saison des Jeux Olympiques",
    y = "Poids de l'athlète (en kg)",
    fill = "Saison :"
  ) +
  theme_minimal() +
  theme(
    plot.title = element_text(face = "bold", size = 14),
    legend.position = "top"
  )
)
```

```
## Warning: The 'draw_quantiles' argument of 'geom_violin()' is deprecated as of ggplot2
## 4.0.0.
## i Please use the 'quantiles.linetype' argument instead.
## This warning is displayed once per session.
## Call 'lifecycle::last_lifecycle_warnings()' to see where this warning was
## generated.
```

Comparaison de la distribution du poids des athlètes selon la saison



Interprétation : On peut voir que la distribution de poids est très similaire sur les deux saisons, ce qui ne valide pas notre hypothèse. La forme des violons est presque identique, et les médianes sont au même niveau, ce qui montre que la moyenne des profils sur les deux saisons est similaire. Mais une partie de notre hypothèse est bonne quand même, car on voit des profils beaucoup plus lourds sur les Jeux d'été, qui peuvent venir des sports de lancer, ou de combats, ou d'autres sports, qui ne sont pas présents aux Jeux d'hiver.

Question 8 : Quelles sont les disciplines sportives qui comptent le plus grand nombre d'athlètes enregistrés ?


Le but de cette question est de voir quels sont les sports avec le plus d'athlètes, pour voir si certains sports qui ont une plus grande base de joueur en dehors des Jeux Olympiques, ont aussi le plus d'athlètes dans les Jeux Olympiques.

Notre hypothèse est que les sports les plus "gros" et les plus suivis, tels que la natation ou l'athlétisme, auront le plus d'athlètes.

Pour répondre à cette question, nous allons utiliser un diagramme en barres horizontales, en triant par ordre décroissant.

```
data_all_sports <- dataset %>%  
  group_by(sport) %>%  
  summarize(nb_athletes = n_distinct(athlete_id))  
  
ggplot(data_all_sports, aes(x = nb_athletes, y = reorder(sport, nb_athletes))) +
```

```
geom_col(fill = "darkcyan", color = "white") +
labs(
  title = "Répartition des disciplines sportives par nombre d'athlètes",
  x = "Nombre d'athlètes uniques",
  y = "Discipline sportive"
) +
theme_minimal()
```




Interprétation : Dans ce graphique, le nom des sports est difficilement lisible, nous allons donc en faire un second avec seulement le top 5 des sports, mais on peut quand même voir avec ce graphique que la différence entre le nombre d'athlètes entre les plus représentés et les moins représentés n'est pas énorme, tous les sports ayant entre 200 et 300 athlètes.

```
data_top_sports <- dataset %>%
  group_by(sport) %>%
  summarize(nb_athletes = n_distinct(athlete_id)) %>%
  slice_max(order_by = nb_athletes, n = 5)

ggplot(data_top_sports, aes(x = nb_athletes, y = reorder(sport, nb_athletes))) +
  geom_col(fill = "darkcyan", color = "white", width = 0.6) +
  coord_cartesian(xlim = c(200, 290)) +
  scale_x_continuous(breaks = seq(200, 290, by = 10)) +
  labs(
    title = "Zoom sur la zone au-dessus de 200 athlètes pour observer précisément les écarts",
  )
```

```
x = "Nombre d'athlètes uniques",
y = "Discipline sportive"
) +
theme_minimal()
```



Interprétation : On peut voir que les 5 sports avec le plus d'athlètes ne sont pas les sports les plus "gros" auxquels on pensait pendant notre hypothèse, mais ce sont d'autres sports. Ces 5 sports ont seulement une différence de 10 athlètes, ce qui est très peu.


On peut donc en tirer que soit notre jeu de données n'est pas une liste de tous les athlètes, mais est un échantillon choisi de manière équilibrée pour avoir une représentativité équivalente pour tous les sports, soit il y a plus d'athlètes dans ces 5 sports, que dans les "grands" sports comme la natation ou l'athlétisme.

Question 9 : Corrélation entre expérience olympique et succès

Question : Existe-t-il un "pic d'efficacité" en fonction du nombre de participations (`total_olympics_attended`) ? Est-on plus susceptible de gagner l'or à sa 1ère, 2ème ou 3ème participation ?

Hypothèse : La performance maximale (médaillon d'or) survient plus souvent lors de la deuxième participation (équilibre entre jeunesse et expérience).

Pour répondre à cette question sans être biaisé par le fait qu'il y a beaucoup plus d'athlètes réalisant une seule participation par rapport à ceux en cumulant plusieurs, nous allons créer une **Heatmap (Carte de chaleur)**. Elle affichera la proportion (en pourcentage) de chaque type de résultat selon le nombre de participations.



Interprétation : La carte de chaleur permet de visualiser de façon claire la probabilité d’obtenir une médaille (Or, Argent, Bronze) ou aucune (“None”) selon l’expérience olympique de l’athlète. On remarque généralement que la proportion de “None” baisse à mesure que le nombre de participations augmente, ce qui indique que les athlètes plus expérimentés ont de meilleures chances globales de repartir avec une médaille.

Concernant l’Or spécifiquement, cette visualisation permet de confirmer ou d’infirmer l’hypothèse d’un “pic d’efficacité” : les athlètes participant pour la deuxième ou troisième fois sont statistiquement l’élite de leur discipline, ce qui se reflète souvent par un pourcentage de réussite plus important comparé aux premières participations. L’expérience est donc un facteur clé de succès aux Jeux Olympiques.

Question 10 : L’efficacité des délégations (Ratio Participation/Succès)


Question : Quelles sont les nationalités qui possèdent le meilleur “taux de transformation” (nombre de médailles remportées divisé par le nombre d’athlètes uniques envoyés) ?

Hypothèse : Les grandes nations (avec un grand nombre d’athlètes) remportent le plus grand volume de médailles, mais certaines plus petites délégations ciblées affichent un taux d’efficacité (médailles par athlète) exceptionnel.

Pour répondre à cette question, nous allons croiser le nombre d’athlètes uniques envoyés par pays avec le nombre total de médailles obtenues. Le graphique proposé est un **Scatter Plot (nuage de points)** où : - L’abscisse (X) représente le nombre d’athlètes uniques envoyés par pays. - L’ordonnée (Y) représente le nombre total de médailles remportées. - La taille et la couleur des points reflètent le **taux de transformation** (le pourcentage d’athlètes de la délégation repartant avec une médaille).

Nous filtrons les pays ayant envoyé moins de 10 athlètes pour éviter les cas extrêmes de petites délégations qui fausseraient les statistiques d'efficacité globale.

Efficacité des délégations : Volume vs Efficacité



Interprétation : Le nuage de points permet de distinguer deux stratégies ou dynamiques différentes chez les nations olympiques : 1. **Les géants olympiques :** Situés en haut à droite (grand nombre d'athlètes et grand nombre de médailles). Ces pays envoient d'immenses délégations et convertissent une part significative de leurs athlètes en médaillés. 2. **Les délégations ultra-efficaces :** Situées plus haut par rapport à leur position horizontale (les points rouges/chauds). Ces pays ont un taux de transformation élevé, ce qui signifie qu'une grande partie des athlètes qu'ils envoient réussissent à décrocher une médaille.

Ce graphique illustre parfaitement le compromis entre la quantité d'athlètes engagés et l'optimisation des performances par athlète individuel.