Rapport

data-squad

2026-04-21

Projet IF36 - DataSquad : Analyse des Données Olympiques (1896-2024)

Présentation des données

Les données exploitées dans le cadre de ce projet proviennent d'un jeu de données extrait de la plateforme Kaggle, dans un format en `.csv`. Il contient les informations d'athlètes pendant les Jeux Olympiques de 1896 à 2024.

Nous avons choisi ce set de données car cela nous paraissait très intéressant, nous aimons bien le sport, extraire des statistiques de ce dataset peut-être très instructif. Nous avons vu un potentiel dans ce dataset, il nous permet de nous poser les bonnes questions, qui nous amèneront des graphiques et statistiques pertinents.

Nous avons donc une base de données de 8500 athlètes, avec des données sur 30 catégories. Ces variables couvrent à la fois les résultats sportifs des individus (répartition des médailles, records, valeur des résultats) et leurs profils biométriques et identitaires (pays d'origine, taille, poids, etc.).

Types de données

#	Nom de la colonne	Format donnée	Description	Type
1	`athlete_id`	String	ID unique (format ATH-00001 à ATH-08500)	Discrète (Identifiant)
2	`athlete_name`	String	Nom complet (Prénom + Nom)	Discrète (Nominale)
3	`gender`	String	Sexe de l'athlète (Male/Female)	Discrète (Nominale)
4	`age`	Integer	Âge au moment de l'événement (15–42)	Discrète
5	`date_of_birth`	Date	Date de naissance (YYYY-MM-DD)	Continue (Temporelle)
6	`nationality`	String	Code CIO du pays sur 3 lettres (ex: USA, FRA)	Discrète (Nominale)
7	`country_name`	String	Nom complet du pays	Discrète (Nominale)
8	`sport`	String	Discipline (ex: Athlétisme, Natation)	Discrète (Nominale)
9	`event`	String	Épreuve spécifique (ex: 100m Sprint)	Discrète (Nominale)

#	Nom de la colonne	Format donnée	Description	Type
10	`games_type`	String	Type de jeux (Summer / Winter)	Discrète (Nominale)
11	`year`	Integer	Année des JO (1896–2024)	Discrète (Temporelle)
12	`host_city`	String	Ville hôte des Jeux	Discrète (Nominale)
13	`team_or_individual`	String	Épreuve par équipe ou individuelle	Discrète (Nominale)
14	`medal`	String	Médaille : Gold, Silver, Bronze ou None	Discrète (Ordinale)
15	`result_value`	Float	Résultat chiffré (temps, distance, score)	Continue
16	`result_unit`	String	Unité du résultat (seconds, metres, points, kg)	Discrète (Nominale)
17	`total_olympics`	Integer	Nombre total de JO fréquentés (1–5)	Discrète
18	`total_medals_won`	Integer	Total de médailles en carrière	Discrète
19	`gold_medals`	Integer	Nombre de médailles d'or en carrière	Discrète
20	`silver_medals`	Integer	Nombre de médailles d'argent en carrière	Discrète
21	`bronze_medals`	Integer	Nombre de médailles de bronze en carrière	Discrète
22	`country_total_gold`	Integer	Total historique d'or du pays (jusqu'en 2024)	Discrète
23	`country_total_medals`	Integer	Total historique de médailles du pays	Discrète
24	`country_first_part`	Integer	Année de la première participation du pays	Discrète (Temporelle)
25	`country_best_rank`	Integer	Meilleur classement historique du pays	Discrète (Ordinale)
26	`is_record_holder`	String	Record : World Record / Olympic Record / No	Discrète (Nominale)
27	`coach_name`	String	Nom de l'entraîneur	Discrète (Nominale)
28	`height_cm`	Float	Taille de l'athlète en centimètres	Continue
29	`weight_kg`	Float	Poids de l'athlète en kilogrammes	Continue

#	Nom de la colonne	Format donnée	Description	Type
30	`notes`	String	Contexte supplémentaire (ex: "Personal Best")	Discrète (Texte libre)

Plan d'analyse

Questions de recherche

- **Performance et Morphologie** : Est-ce que la taille/poids d'un athlète influence sa performance ?
- **Temporalité** : Quelles sont les saisons qui sont marquées par un grand nombre de compétitions ?
- **Succès national** : Quels pays remportent le plus de compétitions ?
- **Genre** : Y'a-t-il un genre mis en avant plus qu'un autre ?
- **Représentativité** : Quelles sont les nationalités les plus / moins représentées ?

Interrogations et objectifs

Notre analyse gravite autour d'une problématique centrale : **L'influence de la morphologie (taille et poids) sur la performance athlétique.** Nous cherchons à déterminer si des caractéristiques physiques spécifiques constituent un avantage déterminant pour l'obtention d'une médaille ou d'un record.

Objectifs secondaires : * Existe-t-il une "taille idéale" par discipline sportive ? * Le rapport poids/taille (IMC) est-il plus corrélé à la performance que la taille seule ? * Cette influence morphologique a-t-elle évolué entre les premiers Jeux Olympiques et les éditions récentes (spécialisation des corps) ?

Informations attendues

Nous espérons identifier des clusters d'athlètes performants par sport. Par exemple, nous anticipons une corrélation positive forte entre la taille et la performance en basketball ou en natation, tandis qu'elle pourrait être négative ou inexistante en gymnastique ou en équitation.

Variables comparées et méthodes

Pour valider nos hypothèses, nous allons croiser les variables suivantes : 1. **Taille (height_cm) vs Performance (result_value)** : Utilisation de nuages de points pour visualiser la dispersion et calcul du coefficient de corrélation de Pearson (r). 2. **Poids (weight_kg) vs Sport (sport)** : Comparaison des distributions via des boîtes à moustaches (boxplots) pour voir la variabilité du poids selon la discipline. 3. **Médaille (medal) vs Morphologie** : Analyse par groupes pour voir si les médaillés d'or présentent des caractéristiques physiques distinctes du reste des participants.

Défis et limites potentiels

- **Hétérogénéité des unités** : La variable `result_value` mélange des secondes, des mètres et des points. Il faudra normaliser ces données ou filtrer l'analyse sport par sport.
- **Données manquantes** : Les données historiques comportent souvent des valeurs de poids ou de taille manquantes, ce qui pourrait biaiser l'analyse temporelle.
- **Variables confondantes** : La performance dépend aussi de l'âge, de l'expérience (`total_olympics`) et des infrastructures du pays d'origine.

Rapport de l'étude de base de données :

QUESTION 1: Quels sont les pays qui ont accumulé le plus de médailles d'or au cours de l'histoire des Jeux Olympiques ?

Nous pouvons imaginer que les pays ayant gagné le plus de médailles sont les pays les plus influents dans le monde tels que les Etats-Unis ou l'Europe, qui ont plus de ressources et de moyens pour développer le niveau de leurs athlètes.

Avant de débuter l'analyse, une étape de préparation a été nécessaire sur le jeu de données. Nous avons notamment dû gérer les valeurs manquantes dans les colonnes de médailles en utilisant l'argument "na.rm = TRUE", afin d'éviter que des données non renseignées ne faussent les calculs de sommes globales par pays.

Prendre tous les pays ferait un graphique non lisible, nous avons donc dû choisir de ne prendre que les 15 pays ayant gagné le plus de médailles.

```
dataset %>% group_by(country_name) %>% summarize(country_golds = sum(country_total_gold, na.rm=TRUE)) %>
```

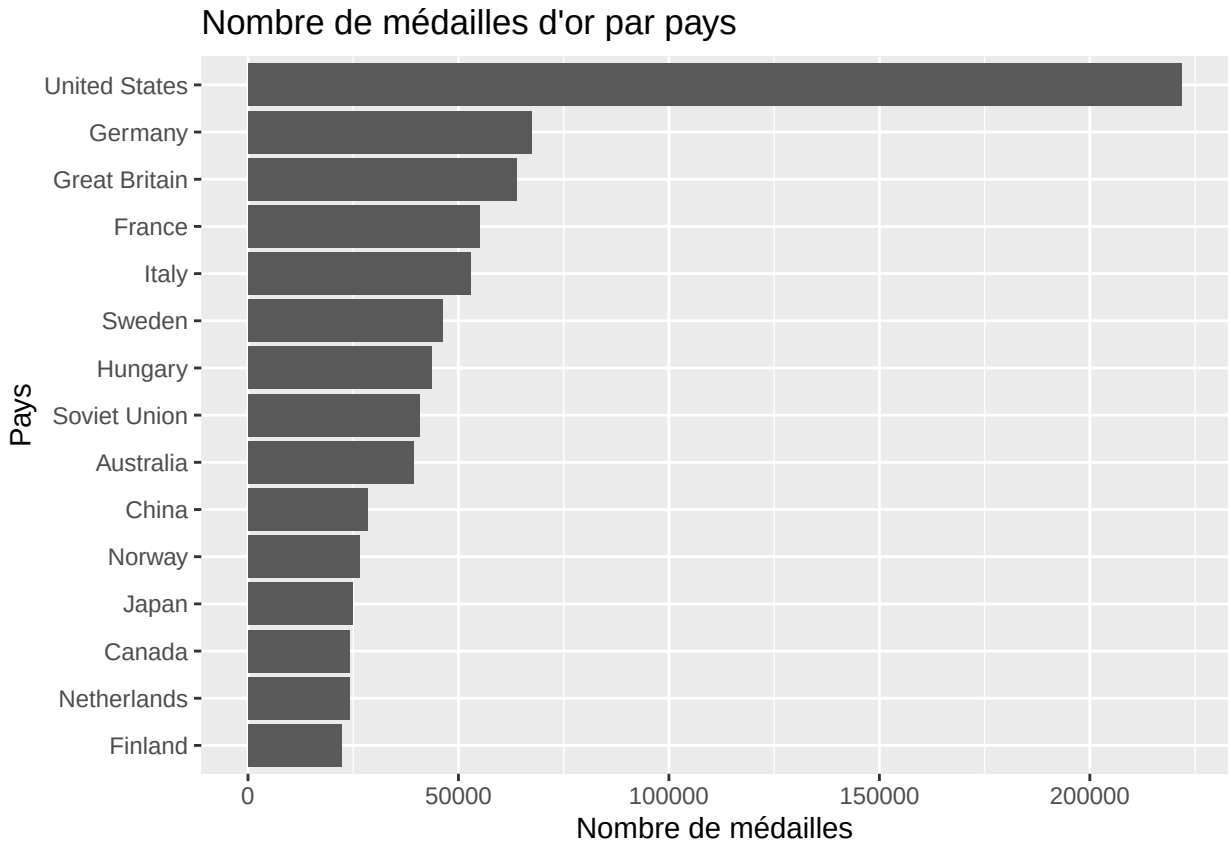

Le graphique confirme en partie notre hypothèse. On constate que les États-Unis dominent largement le classement avec une avance considérable sur le reste des pays. Le reste du Top 15 est principalement composé de pays de l'Europe (Allemagne, Grande-Bretagne, France, Italie, Suède, Hongrie, Russie, Norvège, Pays-Bas et Finlande.), les puissances asiatiques (La Chine et le Japon), ainsi que l'Australie. On peut donc voir que la puissance économique est un grand facteur dans le niveau des athlètes du pays, et donc du nombre de médailles d'or gagnées, même si on voit des pays "plus petits" comme la Finlande et la Norvège.

QUESTION 2 : Quelles sont les nationalités les plus / moins représentées ?

L'objectif de cette partie est d'analyser la représentativité des nationalités dans le dataset des athlètes olympiques.

Graphe 1 — Pays les plus représentés

Choix du graphique

Nous avons choisi un diagramme en barres pour représenter les nationalités les plus présentes dans le dataset. Ce type de graphique est particulièrement adapté à la comparaison de valeurs quantitatives entre différentes catégories. Le choix d'un Top 15 permet d'obtenir une vision suffisamment large des pays dominants tout en conservant une bonne lisibilité.

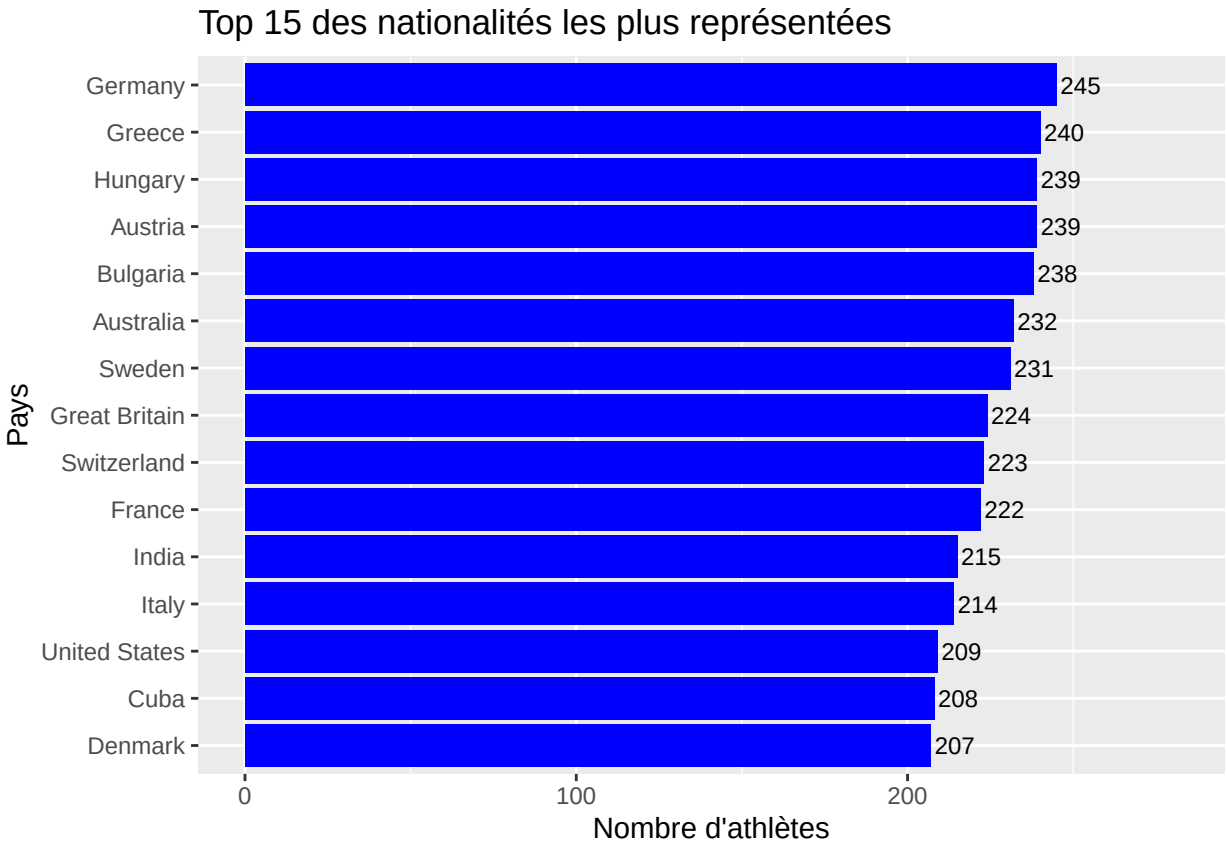

Interprétation

Ce graphique met en évidence les nationalités les plus représentées dans le dataset. Chaque barre correspond à un pays, et sa longueur indique le nombre d'athlètes.

L'un des avantages de ce graphique est qu'il permet de lire des valeurs précises, ce qui facilite la comparaison entre les pays. On observe que certains pays possèdent un nombre d'athlètes nettement supérieur aux autres.

Cela montre une forte concentration des données autour de quelques nationalités dominantes. Cette situation peut s'expliquer par la taille des délégations, la régularité de participation aux Jeux olympiques ou encore les ressources sportives plus importantes de certains pays.

Graphe 2 — Pays les moins représentés

Choix du graphique

Nous avons également choisi un diagramme en barres pour les pays les moins représentés afin de garder une cohérence visuelle avec le premier graphique. Ce choix facilite la comparaison entre les extrêmes du dataset.

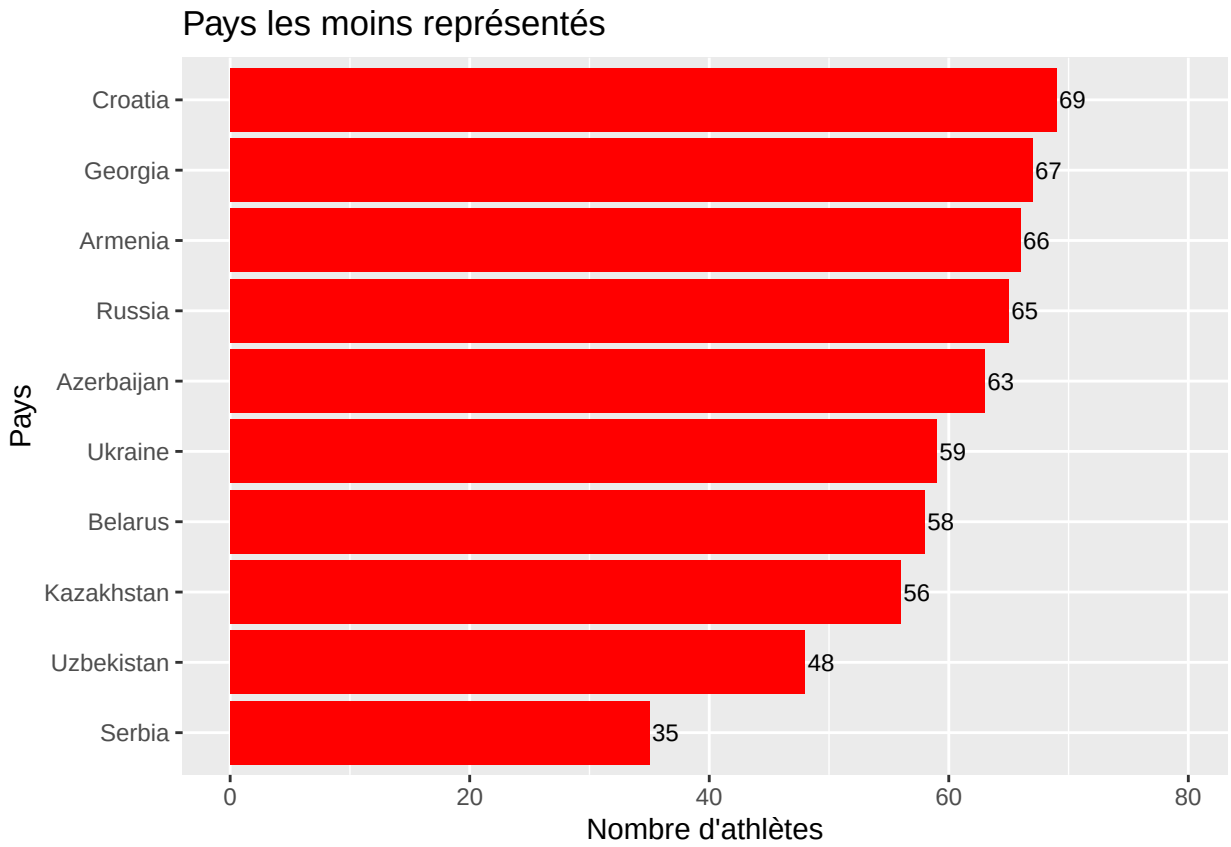

Interprétation

Ce graphique met en évidence les nationalités les moins représentées dans le dataset. Contrairement au premier graphique, les effectifs observés ici sont très faibles et relativement proches les uns des autres.

Cela signifie qu'un grand nombre de pays occupent une place très marginale dans les données. Cette faible représentation peut s'expliquer par une participation plus récente, une présence limitée à certaines disciplines ou des moyens sportifs plus faibles.

Ce graphique complète donc le premier en montrant que la représentativité des nationalités n'est pas uniforme : quelques pays dominent, tandis que beaucoup d'autres sont très peu présents.

Graphe 3 — Comparaison

Choix du graphique

Ce graphique a été choisi pour comparer directement les extrêmes du dataset, c'est-à-dire les pays les plus représentés et les moins représentés. Le fait de les regrouper dans un même espace visuel permet de mettre en évidence immédiatement l'écart entre les deux groupes.

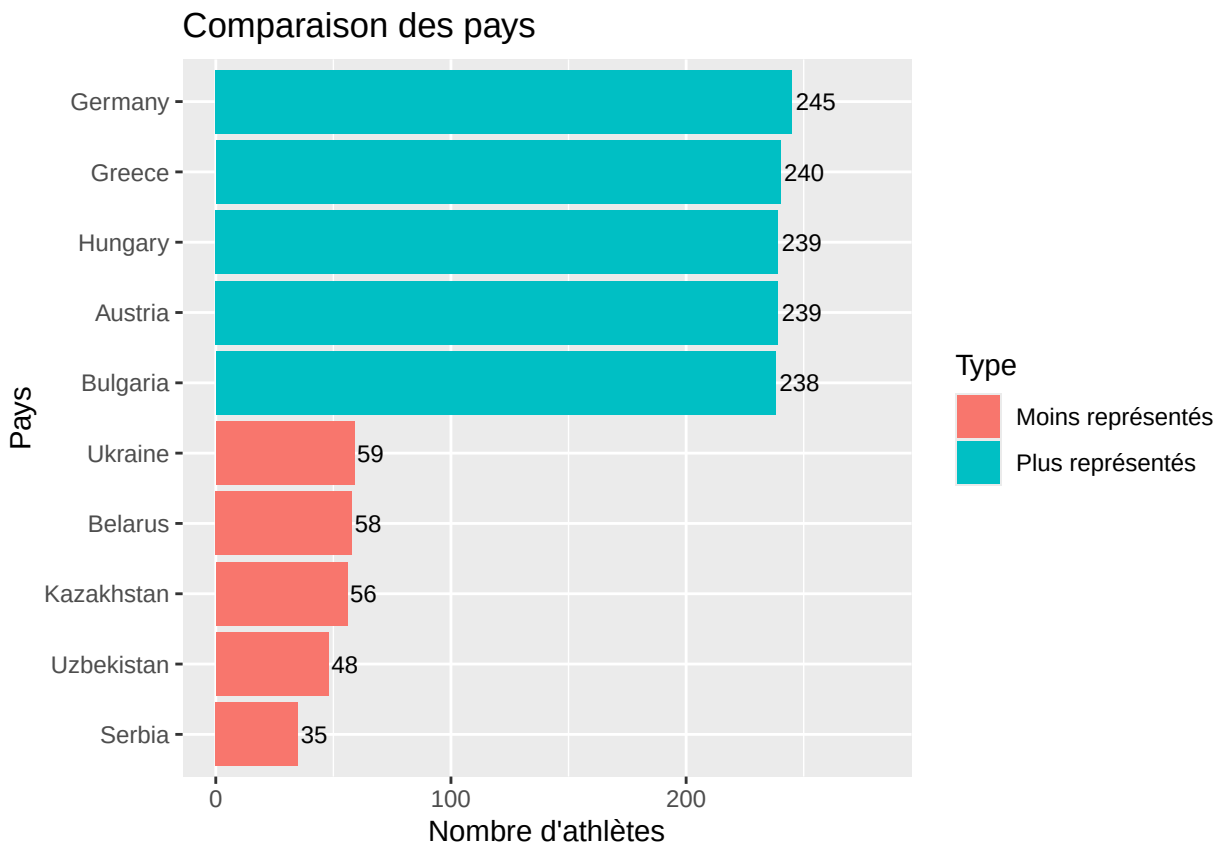

Interprétation

Ce graphique montre clairement l'écart entre les pays les plus représentés et les pays les moins représentés. Les différences de hauteur entre les barres sont très importantes, ce qui rend la comparaison immédiate.

On constate que les pays les plus représentés possèdent un nombre d'athlètes largement supérieur à celui des pays les moins représentés. Cette différence met en évidence une forte inégalité de représentativité dans le dataset.

Ce graphique permet donc de synthétiser les résultats des deux premiers graphes : la distribution des nationalités est fortement déséquilibrée, avec une concentration importante autour de quelques pays.

Conclusion pour Représentativité

L'analyse de ces trois graphiques montre que la représentativité des nationalités dans le dataset est très inégale. Quelques pays concentrent une grande partie des athlètes, tandis qu'un grand nombre de nationalités sont faiblement représentées.

Le premier graphique permet d'identifier les pays dominants avec des valeurs précises. Le deuxième montre que de nombreux pays occupent une place marginale. Enfin, le troisième met directement en évidence l'écart entre ces deux groupes. L'ensemble confirme donc une structure déséquilibrée de la répartition des nationalités.

QUESTION 3: Est-ce que la taille/poids d'un athlète influence sa performance ?

Cette partie analyse si la corpulence d'un athlète (mesurée par l'Indice de Masse Corporelle - IMC) constitue un avantage déterminant pour ses performances.

Force de l'influence de l'IMC par discipline

Ce graphique permet d'identifier les disciplines où la corpulence a l'influence la plus forte sur le résultat (chrono, points, distance).

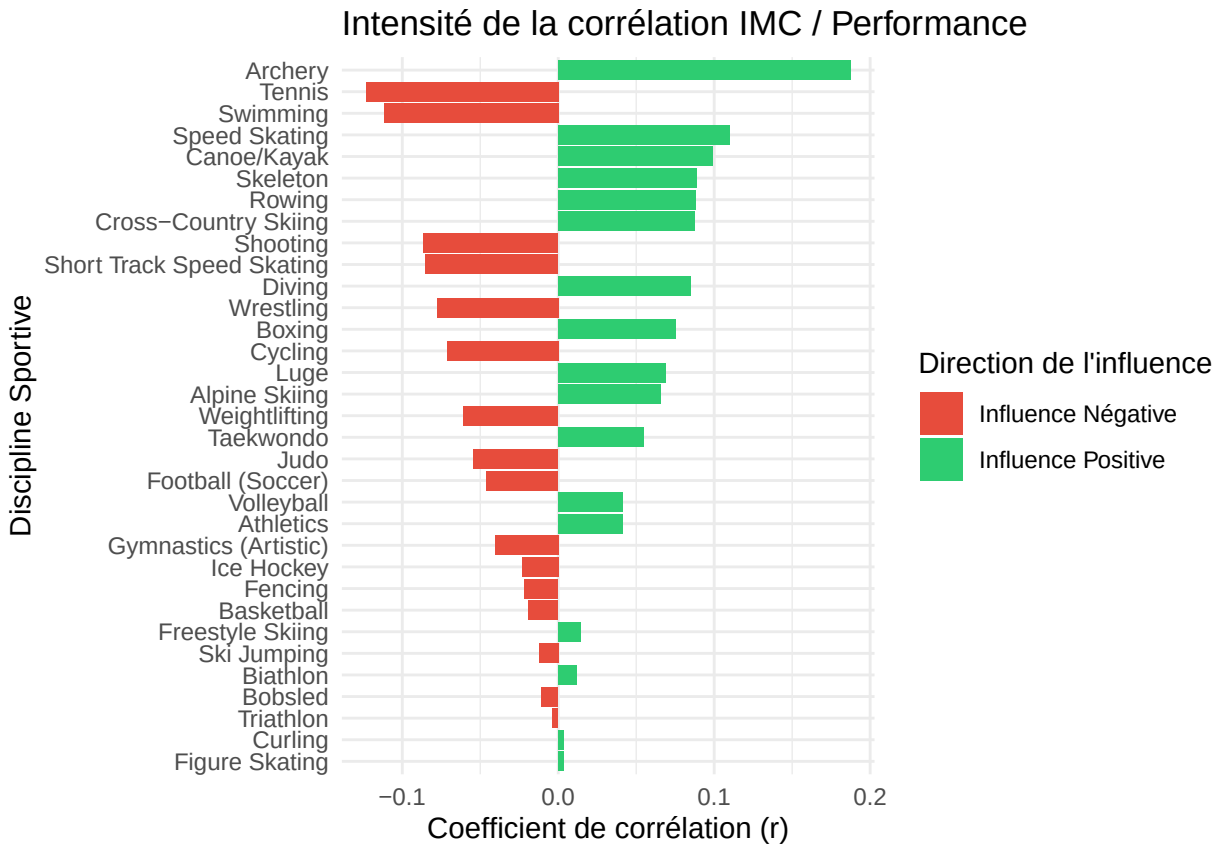

Zoom sur les sports clés

Pour comprendre l'impact réel, nous isolons deux sports aux tendances opposées.

Archery (Tir à l'arc) : Une corrélation positive

En tir à l'arc, le résultat est en **points** (plus c'est haut, mieux c'est).

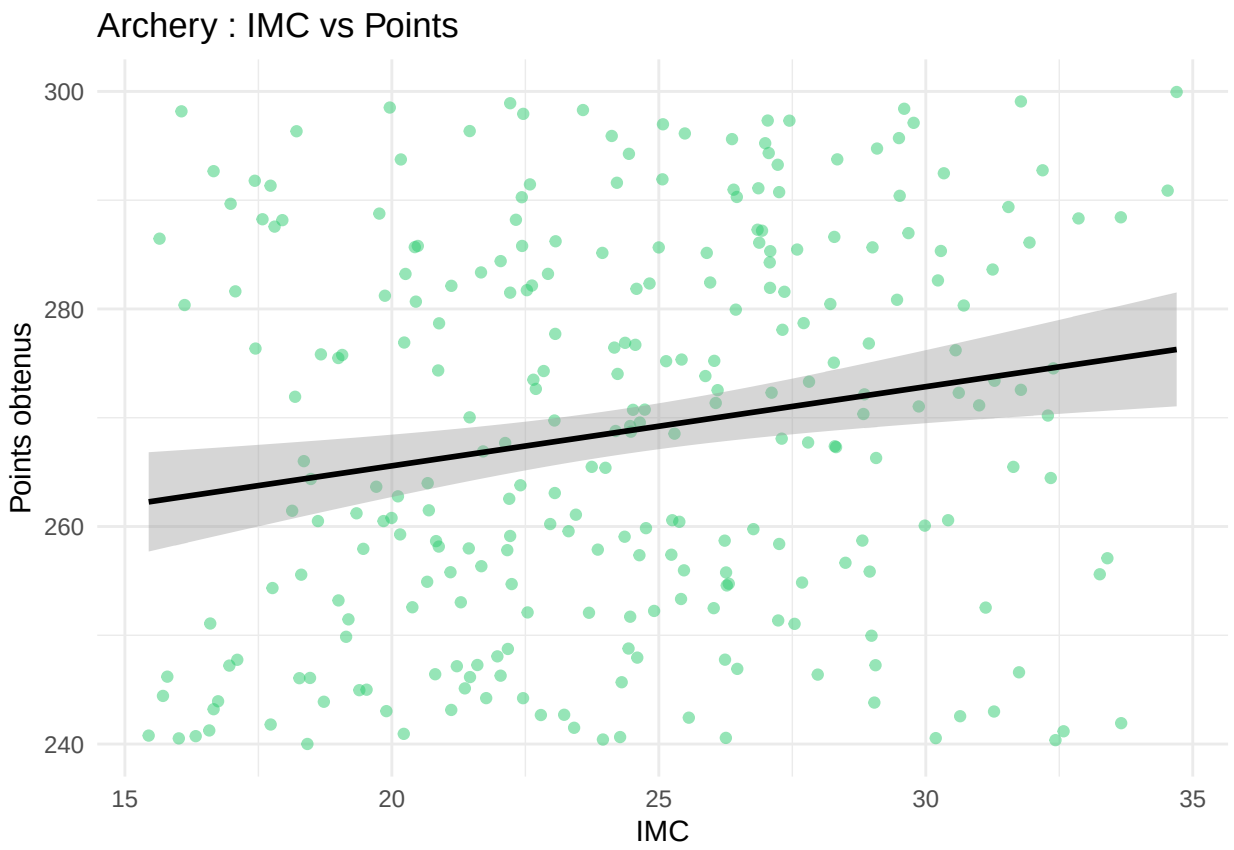

Interprétation : On observe une pente montante. Cela signifie qu'un IMC plus élevé est globalement associé à un meilleur score en points. Une plus grande masse corporelle pourrait offrir une meilleure assise et stabilité face au vent ou lors de la tension de l'arc.

Swimming (Natation) : Une corrélation négative

En natation, le résultat est souvent en **secondes** (plus c'est bas, mieux c'est).

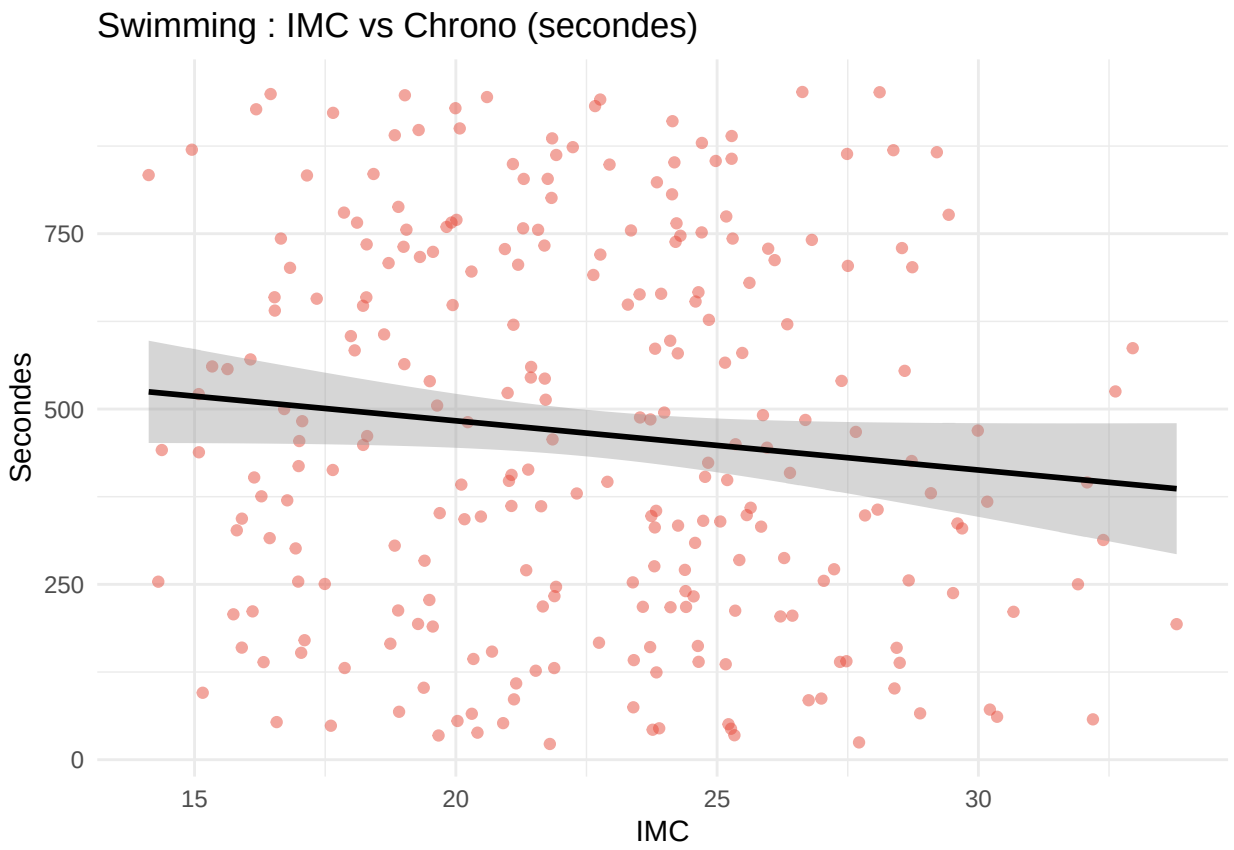

Interprétation : La pente est descendante. Comme le résultat est exprimé en secondes, une baisse du temps signifie une amélioration. On peut en conclure qu'un IMC plus élevé est souvent un avantage pour la propulsion et la puissance dans l'eau chez les nageurs Olympiques.

Conclusion sur la morphologie

En conclusion, notre analyse confirme que l'influence de l'IMC est bien réelle, mais qu'elle est spécifique à chaque discipline. Il est important de noter que les athlètes Olympiques sont, par définition, déjà à leur **poids de forme** optimal pour leur sport. Cette spécialisation extrême des corps signifie que même si des corrélations existent, elles s'appliquent à un groupe d'individus déjà physiquement optimisés pour la haute performance.

Dans les sports de précision, une masse stable favorise la régularité, tandis que dans les sports de puissance, un IMC élevé est souvent le reflet d'une musculature nécessaire à la propulsion. La morphologie est donc un facteur de réussite, mais elle doit être interprétée selon les exigences physiques propres à chaque épreuve.

Question 4 :Y'a t-il un genre mis en avant qu'un autre?

Ici, nous cherchons à répondre à la question suivante : existe-t-il un genre (homme ou femme) mis en avant dans les Jeux Olympiques ?

Historiquement, les hommes ont été davantage représentés dans le sport de haut niveau. Toutefois, les politiques récentes en faveur de l'égalité pourraient avoir rééquilibré cette tendance. On peut donc s'attendre soit à une domination masculine, soit à une répartition plus équilibrée. Il est important de souligner que les résultats basés sur le genre dépendent de pliusieurs facteurs car une femme peut pratiquer des sports "dédiés aux hommes" sachant que l'inverse n'est pas totalement évident.

Afin d'explorer cette question, nous commençons par analyser le nombre de participants par genre pour chaque

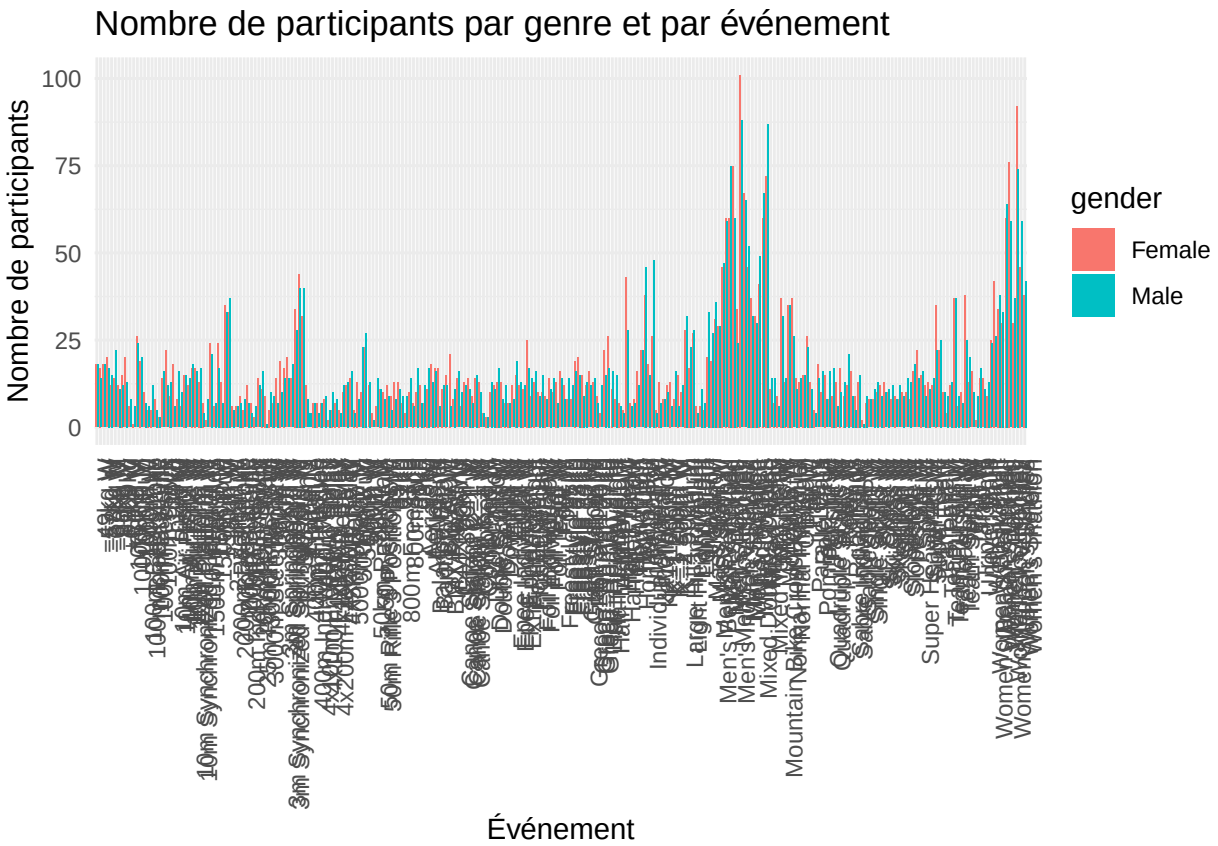

événement.

Ce graphique présente une vue détaillée du nombre de participants par genre pour chaque épreuve.

Cependant, il apparaît rapidement que ce graphique est difficilement exploitable. Le nombre très élevé d'événements rend la lecture complexe et empêche d'identifier des tendances claires.

Ainsi, ce premier résultat ne permet pas de répondre efficacement à la question posée.

Il met néanmoins en évidence la nécessité de simplifier l'analyse afin de mieux faire ressortir les tendances globales.

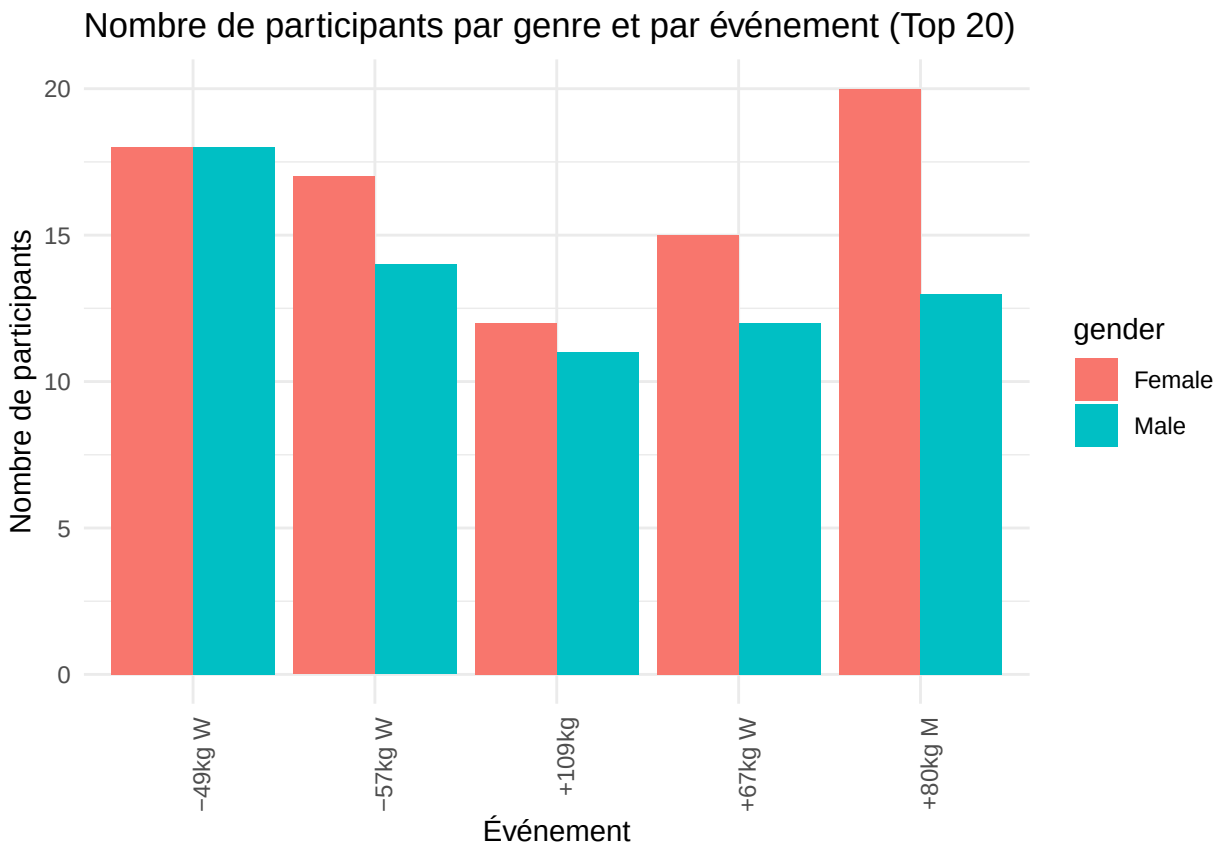

Avec cette sélection, les résultats deviennent plus lisibles. On observe que certains événements présentent des écarts entre hommes et femmes.

Cependant, ces différences s'expliquent principalement par la nature des épreuves (catégories de poids, disciplines distinctes, etc.) et non par une mise en avant globale d'un genre.

Cette analyse reste donc insuffisante pour répondre à la question initiale.

Elle suggère qu'il est préférable d'adopter une approche plus globale.

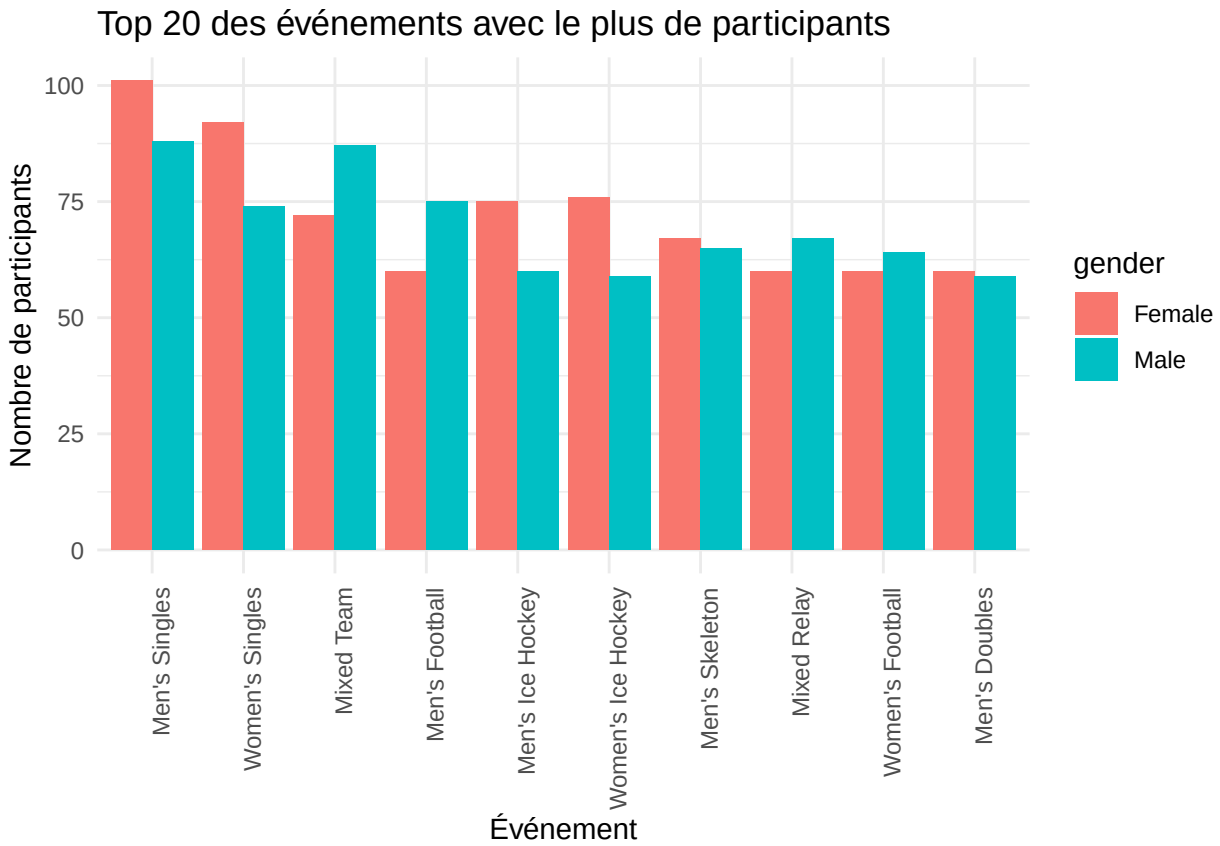

Nous nous intéressons maintenant aux événements regroupant le plus de participants.

Ce graphique met en évidence les 20 événements les plus représentés.

On remarque la présence d'épreuves masculines, féminines, mais aussi mixtes, ce qui reflète une volonté d'inclusion croissante dans les compétitions sportives.

De plus, aucun déséquilibre majeur ne semble apparaître dans ces événements fortement représentés.

Cela suggère que les événements les plus importants ne favorisent pas particulièrement un genre.

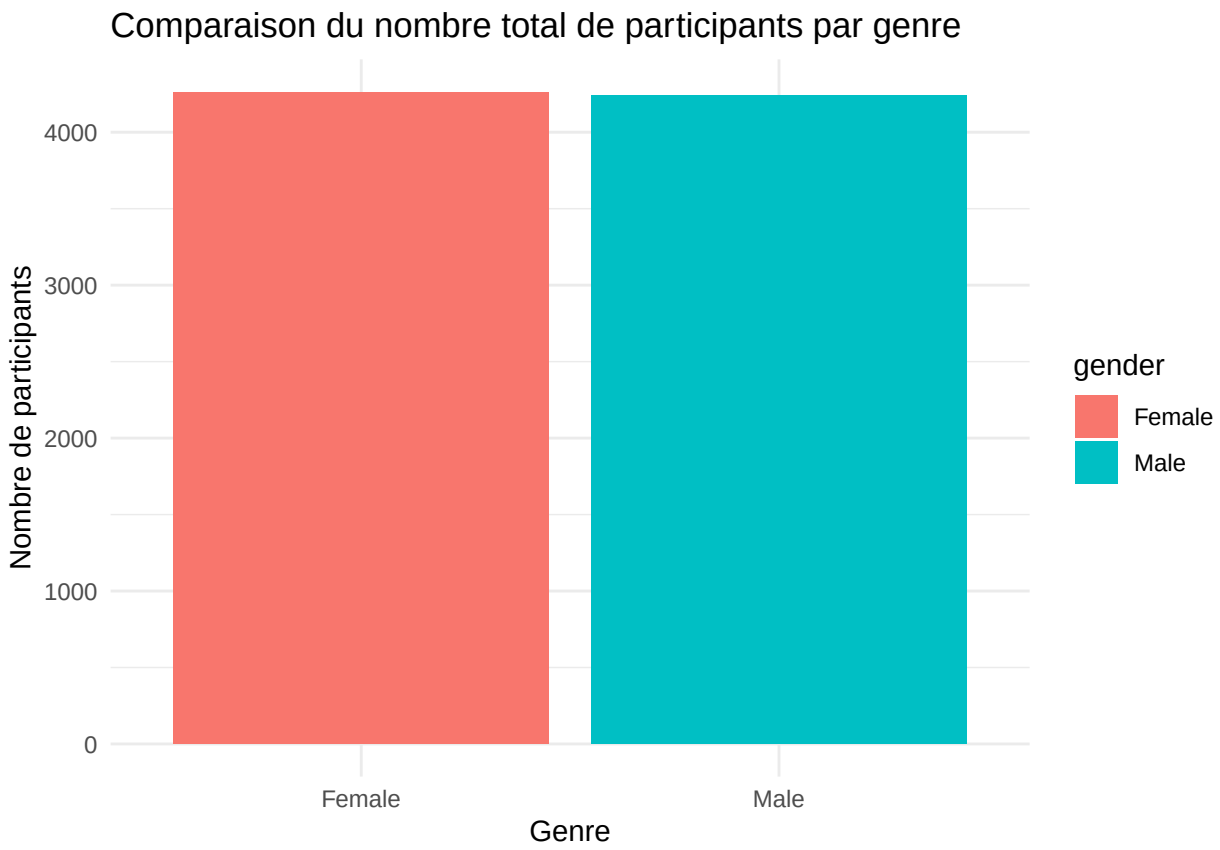

Afin d'obtenir une vision d'ensemble, nous comparons le nombre total de participations par genre.

Les résultats montrent :

Femmes : 4263 participations Hommes : 4237 participations

```
## # A tibble: 2 x 2
##   gender total
##   <chr>  <int>
## 1 Female  4263
## 2 Male    4237
```

Ces valeurs sont très proches, indiquant une quasi-parité.

Cependant, cette mesure peut être biaisée : un même athlète peut participer à plusieurs événements, ce qui gonfle artificiellement les effectifs.

Il est donc nécessaire d'affiner l'analyse.

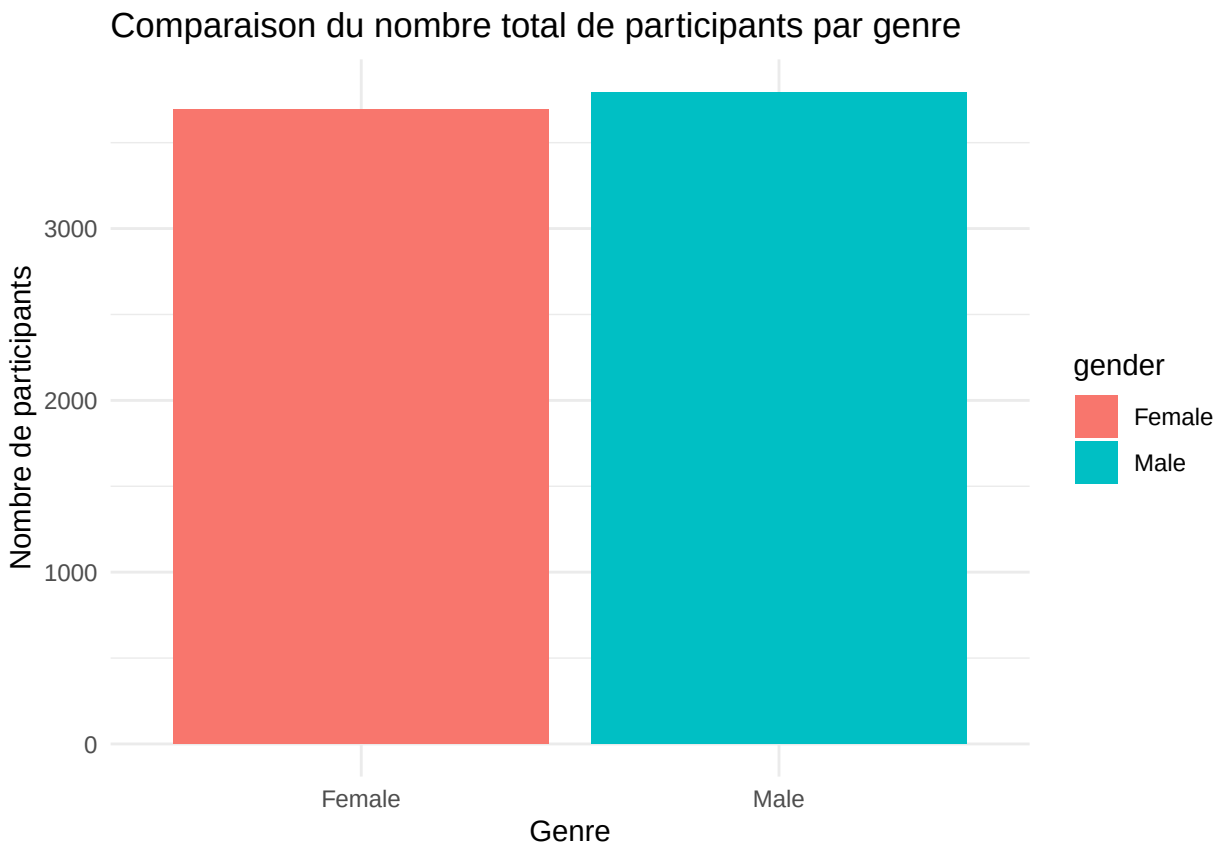

Pour éviter ce biais, nous comptons le nombre d'athlètes uniques par genre.

Les résultats obtenus sont les suivants :

Femmes : 3696 athlètes Hommes : 3795 athlètes

Cette fois, un léger avantage masculin apparaît.

Cependant, l'écart reste modéré et ne traduit pas une domination marquée.

Cette analyse est la plus pertinente car elle reflète le nombre réel d'individus et non le nombre de participations.

```
## # A tibble: 2 x 2
##   gender nb_athletes_uniques
##   <chr>                <int>
## 1 Female                3696
## 2 Male                  3795
```

Conclusion sur le genre

L'ensemble de l'analyse permet de répondre à la question initiale.

Aucun genre n'est clairement mis en avant dans ce dataset.

En effet :

Les écarts observés par événement sont liés à la structure des disciplines Le nombre total de participations est quasiment équilibré Le nombre d'athlètes uniques montre un léger avantage masculin, mais limité

On observe donc une tendance globale vers la parité.

Cette évolution reflète probablement les efforts récents visant à promouvoir l'égalité dans le sport.

Enfin, une piste d'amélioration serait d'analyser l'évolution de cette répartition au fil du temps afin de mieux comprendre les dynamiques historiques.