

Rapport

data-squad

2026-04-21

Projet IF36 - DataSquad : Analyse des Données Olympiques (1896-2024)

Présentation des données

Les données exploitées dans le cadre de ce projet proviennent d'un jeu de données extrait de la plateforme Kaggle, dans un format en `.csv`. Il contient les informations d'athlètes pendant les Jeux Olympiques de 1896 à 2024.

Nous avons choisi ce set de données car cela nous paraissait très intéressant, nous aimons bien le sport, extraire des statistiques de ce dataset peut-être très instructif. Nous avons vu un potentiel dans ce dataset, il nous permet de nous poser les bonnes questions, qui nous amèneront des graphiques et statistiques pertinents.

Nous avons donc une base de données de 8500 athlètes, avec des données sur 30 catégories. Ces variables couvrent à la fois les résultats sportifs des individus (répartition des médailles, records, valeur des résultats) et leurs profils biométriques et identitaires (pays d'origine, taille, poids, etc.).

Types de données

#	Nom de la colonne	Format donnée	Description	Type
1	<code>athlete_id</code>	String	ID unique (format ATH-00001 à ATH-08500)	Discrète (Identifiant)
2	<code>athlete_name</code>	String	Nom complet (Prénom + Nom)	Discrète (Nominale)
3	<code>gender</code>	String	Sexe de l'athlète (Male/Female)	Discrète (Nominale)
4	<code>age</code>	Integer	Âge au moment de l'événement (15-42)	Discrète
5	<code>date_of_birth</code>	Date	Date de naissance (YYYY-MM-DD)	Continue (Temporelle)
6	<code>nationality</code>	String	Code CIO du pays sur 3 lettres (ex: USA, FRA)	Discrète (Nominale)
7	<code>country_name</code>	String	Nom complet du pays	Discrète (Nominale)

#	Nom de la colonne	Format donnée	Description	Type
8	sport	String	Discipline (ex: Athlétisme, Natation)	Discrète (Nominale)
9	event	String	Épreuve spécifique (ex: 100m Sprint)	Discrète (Nominale)
10	games_type	String	Type de jeux (Summer / Winter)	Discrète (Nominale)
11	year	Integer	Année des JO (1896-2024)	Discrète (Temporelle)
12	host_city	String	Ville hôte des Jeux	Discrète (Nominale)
13	team_or_individual	String	Épreuve par équipe ou individuelle	Discrète (Nominale)
14	medal	String	Médaille : Gold, Silver, Bronze ou None	Discrète (Ordinale)
15	result_value	Float	Résultat chiffré (temps, distance, score)	Continue
16	result_unit	String	Unité du résultat (seconds, metres, points, kg)	Discrète (Nominale)
17	total_olympics	Integer	Nombre total de JO fréquentés (1-5)	Discrète
18	total_medals_won	Integer	Total de médailles en carrière	Discrète
19	gold_medals	Integer	Nombre de médailles d'or en carrière	Discrète
20	silver_medals	Integer	Nombre de médailles d'argent en carrière	Discrète
21	bronze_medals	Integer	Nombre de médailles de bronze en carrière	Discrète
22	country_total_gold	Integer	Total historique d'or du pays (jusqu'en 2024)	Discrète
23	country_total_medals	Integer	Total historique de médailles du pays	Discrète
24	country_first_part	Integer	Année de la première participation du pays	Discrète (Temporelle)
25	country_best_rank	Integer	Meilleur classement historique du pays	Discrète (Ordinale)
26	is_record_holder	String	Record : World Record / Olympic Record / No	Discrète (Nominale)

#	Nom de la colonne	Format donnée	Description	Type
27	<code>coach_name</code>	String	Nom de l'entraîneur	Discrète (Nominale)
28	<code>height_cm</code>	Float	Taille de l'athlète en centimètres	Continue
29	<code>weight_kg</code>	Float	Poids de l'athlète en kilogrammes	Continue
30	<code>notes</code>	String	Contexte supplémentaire (ex: "Personal Best")	Discrète (Texte libre)

Plan d'analyse

Questions de recherche

Les questions sont structurées en 4 grands thèmes :

- **MORPHOLOGIE : Impact sur performance** : Analyse des caractéristiques physiques des athlètes (taille, poids, IMC), de leur répartition par discipline, et de leur influence sur la performance (Questions 1 à 8).
- **GÉOPOLITIQUE : Pays dominants** : Étude du succès national, de la domination historique de certains pays, de l'effet d'être pays hôte et de l'efficacité des délégations (Questions 9 à 13).
- **ÉQUITÉ : Genre & représentativité** : Analyse de la parité hommes/femmes, de la représentativité des nationalités et des disciplines sportives, et de l'effet d'âge relatif (Questions 14 à 17).
- **TEMPORALITÉ : Évolution des JO** : Étude de l'évolution de la participation par saison, de l'âge des médaillés, de l'expérience, de la spécialisation des corps dans le temps et de la longévité de carrière (Questions 18 à 23).

Interrogations et objectifs

Notre analyse gravite autour d'une problématique centrale : **L'influence de la morphologie (taille et poids) sur la performance athlétique**. Nous cherchons à déterminer si des caractéristiques physiques spécifiques constituent un avantage déterminant pour l'obtention d'une médaille ou d'un record.

Objectifs secondaires : * Existe-t-il une "taille idéale" par discipline sportive ? * Le rapport poids/taille (IMC) est-il plus corrélé à la performance que la taille seule ? * Cette influence morphologique a-t-elle évolué entre les premiers Jeux Olympiques et les éditions récentes (spécialisation des corps) ?

Informations attendues

Nous espérons identifier des clusters d'athlètes performants par sport. Par exemple, nous anticipons une corrélation positive forte entre la taille et la performance en basketball ou en natation, tandis qu'elle pourrait être négative ou inexistante en gymnastique ou en équitation.

Variables comparées et méthodes

Pour valider nos hypothèses, nous allons croiser les variables suivantes : 1. **Taille (`height_cm`) vs Performance (`result_value`)** : Utilisation de nuages de points pour visualiser la dispersion et calcul du coefficient de corrélation de Pearson (r). 2. **Poids (`weight_kg`) vs Sport (`sport`)** : Comparaison des

distributions via des boîtes à moustaches (boxplots) pour voir la variabilité du poids selon la discipline. 3. **Médaille (medal) vs Morphologie** : Analyse par groupes pour voir si les médaillés d'or présentent des caractéristiques physiques distinctes du reste des participants.

Défis et limites potentiels

- **Hétérogénéité des unités** : La variable `result_value` mélange des secondes, des mètres et des points. Il faudra normaliser ces données ou filtrer l'analyse sport par sport.
- **Données manquantes** : Les données historiques comportent souvent des valeurs de poids ou de taille manquantes, ce qui pourrait biaiser l'analyse temporelle.
- **Variables confondantes** : La performance dépend aussi de l'âge, de l'expérience (`total_olympics`) et des infrastructures du pays d'origine.

Rapport de l'étude de base de données :


MORPHOLOGIE : Impact sur performance

Question 1 : Existe-t-il une corrélation visuelle entre la taille et le poids des athlètes, toutes disciplines confondues ?

Hypothèse : Nous supposons qu'il existe une corrélation positive entre la taille et le poids des athlètes. En général, les athlètes les plus grands ont également tendance à être plus lourds.

Nous nous attendons donc à observer une tendance croissante reliant ces deux variables. Cette analyse permet également de détecter d'éventuelles valeurs aberrantes ou incohérentes dans le dataset.archivé.

Relation entre la taille et le poids des athlètes



Choix du graphique Nous avons choisi un nuage de points car il permet de représenter la relation entre deux variables quantitatives : la taille et le poids. L'ajout d'une ligne de tendance linéaire facilite l'identification d'une corrélation générale entre ces deux caractéristiques physiques.

Interprétation

Ce graphique montre une relation positive entre la taille et le poids. La droite de tendance est croissante, ce qui montre que les athlètes les plus grands ont généralement tendance à être plus lourds. On peut aussi observer une dispersion importante des points autour de cette tendance, ce qui indique que la taille n'est pas le seul facteur influençant le poids. Cette variabilité peut s'expliquer par les différences entre disciplines sportives, certaines favorisant des profils plus légers tandis que d'autres nécessitent davantage de masse corporelle. Malgré cette dispersion, aucune anomalie majeure n'apparaît visuellement et les données semblent globalement cohérentes.

Question 2 : Chaque discipline possède-t-elle une « empreinte morphologique » qui lui est propre ?

Dans la Question 1, on a vu qu'à l'échelle de tous les athlètes, la taille et le poids sont globalement liés. Mais ce nuage mélange des sports très différents : un basketteur et un gymnaste n'ont rien à voir physiquement. On se demande donc ici si chaque discipline occupe sa propre zone dans le plan taille / poids, autrement dit si elle a une « empreinte morphologique » bien à elle.


Notre hypothèse est que oui : comme chaque sport impose ses propres contraintes physiques, on devrait voir des groupes nettement séparés (les basketteurs grands et lourds d'un côté, les gymnastes petits et légers de


l'autre, les haltérophiles plutôt courts mais très massifs, etc.).

Choix du graphique Un simple nuage de points serait illisible avec 8500 athlètes superposés. On utilise donc une carte de densité 2D : au lieu d'afficher chaque athlète, elle colore les zones du plan selon le nombre d'athlètes qui s'y trouvent (plus la zone est claire, plus ils sont nombreux). En mettant une facette par discipline, on peut comparer les empreintes côte à côte. On ajoute ensuite une seconde vue, avec toutes les disciplines sur le même plan et une ellipse par sport qui entoure environ 95 % de ses athlètes : ça résume d'un seul trait la zone occupée par chaque discipline.

Les empreintes morphologiques des disciplines olympiques

Densité de la population d'athlètes dans le plan taille x poids





Interprétation Les deux graphiques vont clairement dans le sens de notre hypothèse : chaque discipline occupe bien sa propre région du plan, et les zones se chevauchent peu.

La gymnastique artistique forme une petite tache compacte en bas à gauche, avec des athlètes petits (autour de 163 cm) et légers (autour de 58 kg), ce qui colle avec les exigences des figures acrobatiques. Le basketball est à l'opposé, en haut à droite, avec des joueurs grands (environ 193 cm) et lourds (environ 100 kg). L'aviron et la natation dessinent des nuages allongés, des gabarits grands mais plutôt secs. L'haltérophilie est le cas le plus frappant : une taille moyenne (autour de 175 cm) mais un poids qui varie énormément, ce qui étire son empreinte vers le haut, parce qu'on y trouve aussi bien des poids plumes que des super-lourds. Le ski de fond, lui, reste sur un gabarit intermédiaire et resserré, typique d'un sport d'endurance.

La vue avec les ellipses confirme tout ça : elles se touchent à peine. Le nuage unique qu'on voyait en Question 1 était donc en réalité la superposition de plusieurs populations bien distinctes. La morphologie n'a rien d'aléatoire ici, c'est une vraie signature de la discipline.


Conclusion La densité 2D s'avère bien plus parlante qu'un nuage de points classique : elle montre qu'il n'y a pas une morphologie « de l'athlète olympique », mais une morphologie par discipline. La suite logique est donc de chercher à résumer ces gabarits par un seul chiffre, l'IMC, pour pouvoir classer les disciplines de la plus légère à la plus lourde.

Question 3 : Peut-on classer les disciplines selon un « gabarit type » mesuré par l'IMC ?

La Question 2 a fait ressortir des empreintes morphologiques bien distinctes. On essaie maintenant de les résumer avec un seul indicateur, l'IMC (le poids divisé par la taille au carré), pour classer les 33 disciplines du gabarit le plus léger au plus lourd.

Notre hypothèse est que les sports de saut, de glisse ou d'esthétique (saut à ski, gymnastique, cyclisme) auront un IMC faible, alors que les sports de force pure (haltérophilie, lutte) auront un IMC élevé. On s'attend donc à un classement progressif et plutôt cohérent.

Choix du graphique On utilise des violons horizontaux, parce qu'ils montrent toute la distribution de l'IMC dans chaque discipline, et pas seulement la moyenne, avec une petite boîte à moustaches au centre pour repérer la médiane. Les disciplines sont rangées par IMC médian croissant et colorées en dégradé, pour qu'on voie le classement d'un seul coup d'œil.



Interprétation Le classement obtenu est très cohérent et va dans le sens de notre hypothèse.

Tout en bas, là où l'IMC est le plus faible, on trouve le saut à ski (IMC médian autour de 19), puis le cyclisme, la gymnastique et le patinage artistique (autour de 21) : des sports où être léger est un avantage

direct, que ce soit pour sauter, tourner ou tenir la distance. Au milieu, autour de 22 à 24, on retrouve la plupart des sports plus « polyvalents » comme la natation, l’escrime, le tennis ou l’athlétisme. Et tout en haut, la lutte (autour de 31) et surtout l’haltérophilie (autour de 33), où la masse musculaire fait directement la performance. On remarque d’ailleurs que le violon de l’haltérophilie est beaucoup plus étiré que les autres : c’est logique, puisque la discipline regroupe des catégories de poids très différentes, des plus légers aux super-lourds.

L’écart entre les deux extrêmes est important, environ 14 points d’IMC, ce qui montre à quel point les exigences physiques changent d’un sport à l’autre.

Conclusion L’IMC se révèle un bon résumé pour « cartographier » les disciplines : il condense en une seule dimension ce que la Question 2 montrait en deux. Après avoir creusé le côté morphologie, on change d’échelle pour passer de l’athlète à la nation, et regarder ce qui distingue les pays sur le plan des médailles.


Question 4 : Existe-t-il une différence en terme de poids, entre les athlètes participant aux Jeux D’été, et ceux des Jeux d’hiver ?

Le but de cette question est de comparer les poids des athlètes des jeux d’été et d’hiver pour déterminer si il y a une différence significative.

Notre hypothèse est qu’il y aura une petite différence de poids, car les sports de Jeux d’hiver se basent sur l’inertie, ce qui pourrait nécessiter une masse supérieure, même si on suppose qu’il y aura des extrêmes plus importants pour l’été, avec par exemple des sport de lancer, qui ne nécessitent pas d’être plus léger.

Pour répondre à cette question, nous allons utiliser un graphique en violon, qui permet de bien voir la distribution, en utilisant aussi des lignes pour voir les différents quantiles, et de pouvoir voir les extrêmes.

Comparaison de la distribution du poids des athlètes selon la sa



Interprétation : On peut voir que la distribution de poids est très similaire sur les deux saisons, ce qui ne valide pas notre hypothèse. La forme des violons est presque identique, et les médianes sont au même niveau, ce qui montre que la moyenne des profils sur les deux saisons est similaire. Mais une partie de notre hypothèse est bonne quand même, car on voit des profils beaucoup plus lourds sur les Jeux d'été, qui peuvent venir des sports de lancer, ou de combats, ou d'autres sports, qui ne sont pas présents aux Jeux d'hiver.


Question 5 : Est-ce que la taille/poids d'un athlète influence sa performance ?

Cette partie analyse si la corpulence d'un athlète (mesurée par l'Indice de Masse Corporelle - IMC) constitue un avantage déterminant pour ses performances.

Force de l'influence de l'IMC par épreuve Afin d'obtenir une analyse plus précise, nous avons affiné notre approche en étudiant non plus uniquement les disciplines sportives globales, mais les couples discipline + épreuve.

Cette précision permet d'éviter qu'un sport regroupant des épreuves très différentes (par exemple la natation ou la gymnastique) masque des relations importantes entre morphologie et performance.

Le graphique suivant présente les 10 épreuves pour lesquelles l'IMC présente la corrélation la plus forte avec la performance, mesurée à l'aide du coefficient de corrélation de Pearson en valeur absolue.



Interprétation Contrairement à l'analyse réalisée au niveau des sports globaux réalisée dans le premier rapport, l'analyse par épreuve révèle des corrélations nettement plus fortes, atteignant $|r| \approx 0.57$.

Les épreuves présentant les corrélations les plus marquées sont :

- **Gymnastics (Artistic) - Parallel Bars**
- **Boxing - Lightweight**
- **Gymnastics (Artistic) - All-Around**
- **Swimming - 400m Freestyle**


Ces résultats montrent qu'une morphologie spécifique peut procurer un avantage mesurable dans certaines épreuves.

Cette analyse suggère également que l'échelle d'analyse est cruciale : observer un sport dans son ensemble peut masquer des tendances importantes visibles uniquement au niveau des épreuves individuelles. Tout dépend de ce que l'on cherche, si un athlète pratique plusieurs épreuves dans un sport alors il vaut mieux rester sur les sport globaux.

Zoom sur les épreuves clés

Pour comprendre l'impact réel, nous isolons deux épreuves aux tendances différentes.


Gymnastics (Artistic) - Parallel Bars : Corrélation positive Dans cette épreuve, la performance est mesurée en points : plus le score est élevé, meilleure est la performance.



La droite de régression présente une pente montante, indiquant qu'un IMC plus élevé est globalement associé à un meilleur score.

Swimming - 400m Freestyle : Corrélation négative En natation, la performance est exprimée en secondes : plus le chrono est faible, meilleure est la performance.

Swimming – 400m Freestyle : IMC vs Chrono (secondes)



Cette relation peut s'expliquer par une meilleure capacité de propulsion, souvent liée à une masse musculaire plus importante.

Conclusion sur la morphologie Notre analyse confirme que l'influence de l'IMC sur la performance est bien réelle, mais qu'elle dépend fortement de l'épreuve étudiée.

L'analyse par épreuve s'est révélée plus pertinente que l'analyse par sport global, car elle met en évidence des corrélations plus fortes et plus significatives.

Ces résultats montrent que la morphologie constitue un facteur important de performance, mais qu'elle ne peut être interprétée indépendamment des exigences biomécaniques propres à chaque épreuve.


Aussi on remarque que le nombre d'athlètes est assez faible par épreuve étant donné que le dataset est un échantillon. Donc cela peut modifier les résultats

Question 6 : La taille des athlètes influence-t-elle davantage les performances mesurées en distance (mètres) que celles mesurées en temps (secondes) ?

Hypothèse : Nous supposons que la taille constitue un avantage plus important dans les disciplines où la performance est mesurée en distance. Des membres plus longs peuvent favoriser certaines actions comme les lancers ou les sauts.

À l'inverse, dans les disciplines chronométrées, la performance dépend davantage de facteurs tels que la vitesse, l'endurance ou la technique. L'influence directe de la taille pourrait donc être moins marquée.

Relation entre la taille et les performances



Choix du graphique Nous avons choisi un nuage de points car il permet d'étudier la relation entre deux variables quantitatives : la taille des athlètes et leur performance. Le graphique est divisé en deux parties selon l'unité de mesure du résultat (« metres » ou « seconds »). Cette séparation permet de comparer visuellement l'effet de la taille dans différents types d'épreuves.

Interprétation

On observe deux nuages de points, l'un pour les épreuves mesurées en mètres et l'autre pour celles mesurées en secondes. Dans les deux cas, les points sont répartis sur une large zone du graphique et ne forment pas de structure particulière. Pour une même taille, on retrouve des athlètes avec des résultats très différents.

Dans le graphique de gauche (metres), les performances sont dispersées sur l'ensemble des tailles observées, entre environ 160 cm et 190 cm. Les meilleurs comme les moins bons résultats sont obtenus par des athlètes de tailles variées.

Dans le graphique de droite (seconds), la dispersion est encore plus importante. La majorité des observations se concentrent dans la partie basse du graphique, mais on observe également plusieurs valeurs très élevées réparties sur presque toutes les tailles.

Visuellement, il est difficile d'identifier une relation claire entre la taille des athlètes et leur performance. Les points ne suivent ni une tendance croissante ni une tendance décroissante marquée. Le graphique met donc surtout en évidence une forte variabilité des résultats pour toutes les tailles observées.

Question 7 : L'écart-type de la taille des athlètes au sein d'une même discipline a-t-il diminué entre 1924 et 2024 ?

Hypothèse :

Nous supposons qu'au fil du temps, les athlètes d'une même discipline ont développé des caractéristiques physiques de plus en plus similaires. Cette évolution traduirait une spécialisation progressive vers un profil physique considéré comme optimal pour chaque sport.

Évolution de l'écart-type de la taille en natation



Choix du graphique Nous avons choisi un graphique en lignes car nous souhaitons observer l'évolution d'une variable au cours du temps. Ce type de représentation permet de visualiser facilement les tendances et les variations de l'écart-type de la taille des athlètes d'une même discipline.

Interprétation Ce graphique montre l'évolution de l'écart-type de la taille des nageurs au cours du temps. L'écart-type varie entre environ 8 et 11 cm selon les éditions des Jeux Olympiques. Bien que certaines fluctuations soient visibles d'une année à l'autre, une légère diminution de la dispersion des tailles semble apparaître sur les années les plus récentes. Cela suggère que les profils physiques des nageurs deviennent progressivement plus homogènes. Toutefois, les variations observées restent relativement importantes, ce qui indique qu'il existe encore une diversité de morphologies au sein de cette discipline. Ainsi, le graphique met en évidence une tendance modérée vers une standardisation des profils physiques, sans pour autant montrer une évolution parfaitement régulière.

Conclusion Cette analyse permet d'étudier l'évolution de la diversité physique des athlètes au sein d'une même discipline. Une diminution de l'écart-type de la taille au cours du temps constituerait un indice de spécialisation progressive des profils physiques.

Question 8 : Application Shiny - un explorateur morphologique interactif

Pour permettre au lecteur d'explorer lui-même les empreintes morphologiques vues en Question 2, nous avons développé une **application Shiny** (dossier /shiny/). Plutôt que de figer un seul graphique, elle laisse l'utilisateur **choisir la discipline, la saison et le genre**, et observer en temps réel comment se déplace le nuage taille $\times$ poids et comment évolue la distribution de l'IMC.

Les figures ci-dessous n'ont pas été générées directement dans ce rapport : ce sont des captures d'écran de l'application Shiny. Pour interagir avec ces graphiques, il faut lancer l'application (/shiny/app.R).




Figure 1: Onglet 1 de l'application Shiny : nuage taille x poids filtré par discipline, saison et genre, points colorés selon la médaille obtenue.




Figure 2: Onglet 2 de l'application Shiny : distribution de l'IMC pour les disciplines sélectionnées (violin interactif).

La première capture (nuage taille $\times$ poids) confirme de manière interactive ce que la Question 2 montrait : en sélectionnant successivement « Basketball » puis « Gymnastics (Artistic) », le nuage se déplace radicalement dans le plan, illustrant en direct la spécialisation des gabarits. Le filtre par saison et par genre permet en outre de vérifier que ces empreintes restent stables (les femmes suivent la même logique morphologique que les hommes, simplement décalée vers des gabarits un peu plus légers).

La seconde capture (violon d'IMC) permet de comparer interactivement deux ou trois disciplines au choix, et retrouve le classement de la Question 3 : l'haltérophilie domine toujours en IMC, la gymnastique reste tout en bas.

Conclusion L'application Shiny transforme une analyse figée en outil d'exploration : elle apporte une valeur ajoutée réelle par rapport à un graphique statique, puisqu'elle laisse le lecteur poser ses propres sous-questions.


GÉOPOLITIQUE : Pays dominants

Question 9 : Quels sont les pays qui ont accumulé le plus de médailles d'or au cours de l'histoire des Jeux Olympiques ?

Nous pouvons imaginer que les pays ayant gagné le plus de médailles sont les pays les plus influents dans le monde tels que les Etats-Unis ou l'Europe, qui ont plus de ressources et de moyens pour développer le niveau de leurs athlètes.

Avant de débiter l'analyse, une étape de préparation a été nécessaire sur le jeu de données. Nous avons notamment dû gérer les valeurs manquantes dans les colonnes de médailles en utilisant l'argument "na.rm = TRUE", afin d'éviter que des données non renseignées ne faussent les calculs de sommes globales par pays.

Prendre tous les pays ferait un graphique non lisible, nous avons donc dû choisir de ne prendre que les 15 pays ayant gagné le plus de médailles.



Le graphique confirme en partie notre hypothèse. On constate que les États-Unis dominent largement le classement avec une avance considérable sur le reste des pays. Le reste du Top 15 est principalement composé


de pays de l'Europe (Allemagne, Grande-Bretagne, France, Italie, Suède, Hongrie, Russie, Norvège, Pays-Bas et Finlande.), les puissances asiatiques (La Chine et le Japon), ainsi que l'Australie. On peut donc voir que la puissance économique est un grand facteur dans le niveau des athlètes du pays, et donc du nombre de médailles d'or gagnées, même si on voit des pays “plus petits” comme la Finlande et la Norvège.

Question 10 : Quelles nations sont des « machines à or » et lesquelles sont des « collectionneuses de médailles » ?

La Question 9 a classé les pays selon le volume brut de médailles d'or. Mais gagner beaucoup de médailles n'est pas tout à fait la même chose que dominer. On s'intéresse donc ici à la part d'or dans le palmarès total de chaque nation (`country_total_gold / country_total_medals`), ce qu'on appelle son « ratio d'or ».

Notre hypothèse est que certaines nations « dominatrices » transforment une grande partie de leurs podiums en or, tandis que d'autres « collectionnent » des médailles sans souvent atteindre la première marche. On s'attend aussi à voir apparaître des spécialistes : de petits pays très riches en or, mais sur une poignée de disciplines seulement.

Choix du graphique On utilise un graphique en sucettes (un segment terminé par un point), qui reste plus lisible qu'un diagramme en barres quand on compare une cinquantaine de pays. Les pays sont rangés par ratio d'or décroissant. La taille du point correspond au total de médailles, ce qui permet de distinguer les géants des petites délégations, et sa couleur reprend le ratio. On écarte volontairement les pays ayant moins de 30 médailles au total : sur un dénominateur aussi faible, le ratio deviendrait trop instable pour être interprété.



Interprétation On distingue assez nettement trois profils de nations sur ce graphique.

D'abord les géants : l'Union soviétique (autour de 42 %), la Chine (41 %) et les États-Unis (40 %), qui sont à la fois en haut du classement et représentés par de gros points. Ils cumulent donc un énorme volume de médailles et un ratio d'or élevé, ce sont les vraies puissances, celles qui ne se contentent pas de monter sur le podium mais qui gagnent. Ensuite les spécialistes, avec des points beaucoup plus petits mais un ratio tout aussi haut : l'Éthiopie (autour de 44 %), le Nigeria ou la Turquie (autour de 40 %). Ces pays dominent visiblement quelques disciplines bien ciblées, ce qui colle avec la réalité (l'Éthiopie, par exemple, est historiquement très forte sur le fond). Enfin, en bas du classement, les « collectionneuses » comme le

Mexique (19 %), la Pologne, la Bulgarie ou le Brésil (autour de 24 %), qui accumulent les podiums mais transforment plus rarement en or.

Il faut toutefois rester prudent : l'éventail des ratios reste assez resserré (de 19 % à 44 %), et sur ce jeu de données la part d'or tourne globalement autour de 30 à 40 %. C'est donc surtout la taille des points, c'est-à-dire le volume, qui sépare le mieux les vraies puissances des nations de niche.

Conclusion En croisant le volume (la taille des points) et la qualité (le ratio d'or), ce graphique résume bien la hiérarchie olympique : il sépare les nations qui gagnent gros, celles qui gagnent juste, et celles qui gagnent souvent sans aller chercher le titre.


Question 11 : L'efficacité des délégations (Ratio Participation/Succès)


Quelles sont les nationalités qui possèdent le meilleur "taux de transformation" (nombre de médailles remportées divisé par le nombre d'athlètes uniques envoyés) ?

Notre hypothèse est que les grandes nations (avec un grand nombre d'athlètes) remportent le plus grand volume de médailles, mais certaines plus petites délégations ciblées affichent un taux d'efficacité (médailles par athlète) exceptionnel.

Pour répondre à cette question, nous allons visualiser directement le taux de transformation en fonction de la taille de la délégation. Le graphique proposé est un Scatter Plot où : - L'abscisse représente le nombre d'athlètes uniques envoyés par pays (sur une échelle logarithmique pour mieux espacer les petites et grandes délégations). - L'ordonnée représente le taux de transformation (%). - La taille des points reflète le nombre total de médailles remportées, permettant de repérer facilement les "géants" comme les États-Unis (USA).

Nous filtrons les pays ayant envoyé moins de 10 athlètes pour éviter les cas extrêmes de petites délégations qui fausseraient les statistiques d'efficacité globale.





Interprétation

Ce graphique montre que les grandes délégations, comme les États-Unis ou l'Allemagne, remportent beaucoup de médailles grâce à leur grand nombre d'athlètes, mais n'ont pas forcément le meilleur taux de réussite.

À l'inverse, certains pays comme Hong Kong, le Portugal ou le Kenya envoient moins d'athlètes mais affichent un taux de transformation plus élevé, ce qui indique une meilleure efficacité par athlète.

On distingue donc deux stratégies : certaines nations misent sur le volume, tandis que d'autres se montrent plus performantes avec des délégations plus réduites. Cela suggère que la taille de la délégation n'explique pas à elle seule le succès olympique.

Question 12 : Le pays hôte affiche-t-il une augmentation de son ratio de médailles par rapport à sa moyenne historique ?


Nous cherchons, dans cette question, à chercher si il y a un nombre plus élevé de médailles pour les pays hôte des Jeux Olympiques, l'année où ils sont hôtes, par rapport à la valeur globale des médailles de ce pays.

Notre hypothèse est que pendant les années où un pays est hôte, le pays surperforme grâce à l'aide mentale qu'apporte le soutien du public, le support mental du fait de vouloir performer dans son pays, ainsi que les investissements massifs entraînés par la présence des Jeux Olympiques.

Pour répondre à cette question, nous allons utiliser un bar chart, qui nous montrera une comparaison entre la moyenne du nombre de médailles que les pays ont pendant les années des Jeux Olympiques, et le nombre de médailles que le pays gagne quand il est hôte des Jeux Olympiques. La complication de cette question

était de relier les valeurs de la variable `host_city` avec la variable `nationality`, ce qui a été fait en utilisant la fonction `tibble::tribble`.

Comparaison des médailles par édition pour les nations hôtes du



Interprétation : On peut donc voir dans ce graphique qu'il y a pour chaque pays analysé, la barre des années où le pays est hôte est plus haute, à peu près de 30 % en moyenne, que la moyenne des pays pendant les Jeux Olympiques. On peut donc en comprendre que notre hypothèse est validée, il y a bien un avantage à domicile, qui fait qu'il y a plus de médailles les années où le pays est hôte des Jeux Olympiques.



Question 13 : L'ancienneté olympique et le rang historique d'une nation prédisent-ils son palmarès ?

On quitte l'athlète pour s'intéresser à la nation. Le jeu de données contient plusieurs agrégats par pays : l'année de première participation (`country_first_participation`), le total historique de médailles (`country_total_medals`) et le meilleur classement jamais atteint (`country_best_rank`). On se demande si ces variables sont liées : un pays présent depuis longtemps, ou déjà très bien classé, gagne-t-il plus de médailles ?

Notre hypothèse est que oui. Les nations présentes dès 1896 et celles qui ont déjà atteint le sommet du classement (rang 1) devraient avoir accumulé un palmarès bien supérieur. On s'attend donc à une corrélation négative entre l'année de première participation et le total de médailles (plus on arrive tôt, plus on accumule), et entre le meilleur rang et le total (un meilleur rang correspond à un chiffre plus petit, donc à davantage de médailles).

Choix du graphique Comme les colonnes `country_*` ne prennent qu'une seule valeur par pays, on commence par réduire le jeu de données à une ligne par pays. On trace ensuite deux nuages de points,

chacun accompagné d'une droite de régression linéaire pour faire apparaître la tendance. Le total de médailles variant énormément (de 5 à plus de 2600), on passe l'axe vertical en échelle logarithmique, sinon les petits pays seraient écrasés tout en bas. Quelques pays au gros palmarès sont annotés pour servir de repères.



Interprétation Les deux panneaux valident notre hypothèse, mais avec des forces très différentes.

Pour l'ancienneté (r autour de $-0,37$), la tendance existe mais reste modérée. Les nations fondatrices (États-Unis, France, Grande-Bretagne, Allemagne, toutes présentes dès 1896) figurent bien parmi les plus médaillées. Mais la corrélation est loin d'être parfaite : la Chine (première participation en 1932) et l'Union soviétique (1952) sont arrivées tard tout en étant aujourd'hui parmi les toutes premières au palmarès. Autrement dit, arriver tôt aide, mais la puissance démographique et l'investissement comptent visiblement plus.

Pour le meilleur rang (r autour de $-0,63$), la corrélation est nettement plus forte. Avoir déjà atteint le rang 1 va presque toujours de pair avec un énorme total de médailles, ce qui est logique : ce sont au fond deux façons de mesurer la même domination sportive.

On voit bien au passage pourquoi l'échelle logarithmique était nécessaire : sans elle, les États-Unis (autour de 2638 médailles) écraseraient à eux seuls tout le graphique.

Conclusion Le rang historique est donc un bien meilleur indicateur du palmarès que la simple ancienneté. Cela vient compléter ce qu'on a vu plus tôt dans cette partie : après le volume de médailles d'or (Question 9), la part d'or (Question 10) et l'efficacité des délégations (Question 11), on constate ici que le palmarès d'une nation reflète surtout une domination installée dans la durée.

ÉQUITÉ : Genre & représentativité


Question 14 : Y a-t-il un genre plus représenté que l'autre ?

Ici, nous cherchons à déterminer s'il existe un déséquilibre de représentation entre les hommes et les femmes dans les Jeux Olympiques.

Notre hypothèse part d'un constat historique : les hommes ont longtemps été plus représentés dans le sport de haut niveau. Mais les politiques récentes en faveur de l'égalité ont pu rééquilibrer les choses. On peut donc s'attendre soit à une domination masculine encore visible, soit à une répartition devenue à peu près paritaire.


Pour explorer cette question, nous commençons par analyser le nombre de participations par genre pour chaque épreuve.

Nombre de participants par genre et par événement




Ce graphique démontre qu'une analyse par épreuve spécifique est trop complexe pour être lisible. Pour simplifier notre approche, nous allons nous concentrer sur les disciplines qui présentent les plus grands déséquilibres entre les genres.

Les 8 sports avec les plus fortes disparités de genre Nous avons sélectionné les 8 sports où l'écart numérique entre les participants masculins et féminins est le plus marqué.



Ce graphique permet de comparer la participation des hommes et des femmes dans les disciplines où l'écart est le plus marqué. En observant les hauteurs des barres, on remarque par exemple que la luge, le patinage artistique et le hockey sur glace comptent davantage de participantes que de participants dans ce dataset. À l'inverse, des disciplines comme le tir à l'arc, l'aviron ou encore le football présentent une représentation masculine légèrement plus importante.


Le choix d'un diagramme en barres côte à côte facilite la comparaison visuelle entre les deux genres pour chaque sport. Cette représentation permet d'identifier rapidement les disciplines où la parité est la moins respectée et d'évaluer l'importance des écarts observés.



Afin d'obtenir une vision globale de la répartition des athlètes, nous avons comparé le nombre total de participants selon le genre. Le diagramme en barres est particulièrement adapté à cette comparaison puisqu'il permet de visualiser rapidement les effectifs de chaque catégorie.

Les résultats montrent une répartition très équilibrée entre les femmes et les hommes. On compte 4 263 participantes contre 4 237 participants, soit un écart de seulement 26 athlètes. Les deux barres ont pratiquement la même hauteur.

Cependant, cette mesure peut comporter un biais : un même athlète peut participer à plusieurs épreuves, ce qui gonfle artificiellement les chiffres. Il est donc nécessaire d'affiner l'analyse.



Pour lever ce biais, nous comptons désormais le nombre d'athlètes uniques par genre. Les résultats sont les suivants :

Cette fois, un léger avantage masculin apparaît. Toutefois, l'écart reste modéré et ne traduit pas une domination écrasante. Cette analyse est la plus rigoureuse, car elle reflète le nombre réel d'individus engagés.

Conclusion sur la parité de genre Au final, l'analyse répond bien à la question de départ : aucun genre n'est nettement privilégié dans ce jeu de données. Le volume total de participations est quasiment identique entre les deux sexes (4 263 femmes contre 4 237 hommes), et le décompte des athlètes uniques fait juste apparaître un léger avantage masculin (3 795 contre 3 696), sans rien qui ressemble à une domination.

Cet équilibre quasi parfait est d'ailleurs à prendre avec un peu de recul : il vient sans doute en partie de la façon dont la base a été construite (un échantillon visiblement équilibré) plutôt que d'être la photo exacte de la parité réelle aux Jeux. Mais sur les données dont on dispose, le constat est clair : on est très proche de la parité.


Question 15 : Quelles sont les nationalités les plus / moins représentées ?

L'objectif de cette partie est d'analyser la représentativité des nationalités dans le dataset des athlètes olympiques.

Graphe 1 - Pays les plus représentés

Choix du graphique Nous avons choisi un diagramme en barres pour représenter les nationalités les plus présentes dans le dataset. Ce type de graphique est particulièrement adapté à la comparaison de valeurs

quantitatives entre différentes catégories. Le choix d'un Top 15 permet d'obtenir une vision suffisamment large des pays dominants tout en conservant une bonne lisibilité.



Interprétation


Ce graphique met en évidence les nationalités les plus représentées dans le dataset. Chaque barre correspond à un pays, et sa longueur indique le nombre d'athlètes.

L'un des avantages de ce graphique est qu'il permet de lire des valeurs précises, ce qui facilite la comparaison entre les pays. On observe que certains pays possèdent un nombre d'athlètes nettement supérieur aux autres.

Cela montre une forte concentration des données autour de quelques nationalités dominantes. Cette situation peut s'expliquer par la taille des délégations, la régularité de participation aux Jeux olympiques ou encore les ressources sportives plus importantes de certains pays.

Graph 2 - Pays les moins représentés

Choix du graphique Nous avons également choisi un diagramme en barres pour les pays les moins représentés afin de garder une cohérence visuelle avec le premier graphique. Ce choix facilite la comparaison entre les extrêmes du dataset.



Interprétation


Ce graphique met en évidence les nationalités les moins représentées dans le dataset. Contrairement au premier graphique, les effectifs observés ici sont très faibles et relativement proches les uns des autres.

Cette faible représentation peut s'expliquer par une participation plus récente, une présence limitée à certaines disciplines ou des moyens sportifs plus faibles.

Ce graphique complète donc le premier en montrant que la représentativité des nationalités n'est pas uniforme : quelques pays dominant, tandis que d'autres sont très peu présents.

Graphe 3 - Comparaison

Choix du graphique Ce graphique a été choisi pour comparer directement les extrêmes du dataset, c'est-à-dire les pays les plus représentés et les moins représentés. Le fait de les regrouper dans un même espace visuel permet de mettre en évidence immédiatement l'écart entre les deux groupes.



Interprétation

Ce graphique montre clairement l'écart entre les pays les plus représentés et les pays les moins représentés. Les différences de hauteur entre les barres sont très importantes, ce qui rend la comparaison immédiate.

On constate que les pays les plus représentés possèdent un nombre d'athlètes largement supérieur à celui des pays les moins représentés. Cette différence met en évidence une forte inégalité de représentativité dans le dataset.

Ce graphique permet donc de synthétiser les résultats des deux premiers graphes : la distribution des nationalités est fortement déséquilibrée, avec une concentration importante autour de quelques pays.

Conclusion L'analyse de ces trois graphiques montre que la représentativité des nationalités dans le dataset est très inégale. Quelques pays concentrent une grande partie des athlètes, tandis que certaines nationalités sont faiblement représentées.


Le premier graphique permet d'identifier les pays dominants avec des valeurs précises. Le deuxième montre qu'il y a aussi des pays avec peu de représentants. Enfin, le troisième met directement en évidence l'écart entre ces deux groupes. L'ensemble confirme donc une structure déséquilibrée de la répartition des nationalités.

Question 16 : Quelles sont les disciplines sportives qui comptent le plus grand nombre d'athlètes enregistrés ?


Le but de cette question est de voir quels sont les sports avec le plus d'athlètes, pour voir si certains sports qui ont une plus grande base de joueur en dehors des Jeux Olympiques, ont aussi le plus d'athlètes dans les Jeux Olympiques.

Notre hypothèse est que les sport les plus “gros” et les plus suivis, tels que la natation ou l’athlétisme, auront le plus d’athlètes.

Pour répondre à cette question, nous allons utiliser un diagramme en barres horizontales, en triant par ordre décroissant.



Interprétation : Dans ce graphique, le nom des sports est difficilement lisible, nous allons donc en faire un second avec seulement le top 5 des sports, mais on peut quand même voir avec ce graphique que la différence entre le nombre d’athlètes entre les plus représentés et les moins représentés n’est pas énorme, tous les sports ayant entre 200 et 300 athlètes.



Interprétation : On peut voir que les 5 sports avec le plus d'athlètes ne sont pas les sports les plus "gros" auxquels on pensait pendant notre hypothèse, mais ce sont d'autres sports. Ces 5 sports ont seulement une différence de 10 athlètes, ce qui est très peu.

On peut donc en tirer que soit notre jeu de données n'est pas une liste de tous les athlètes, mais est un échantillon choisi de manière équilibrée pour avoir une représentativité équivalente pour tous les sports, soit il y a plus d'athlètes dans ces 5 sports, que dans les "grands" sports comme la natation ou l'athlétisme.

Question 17 : Le phénomène de l'Effet d'Âge Relatif (Relative Age Effect)


Ce phénomène est un grand classique de la data science sportive. Il s'agit de vérifier si le mois de naissance influence les chances de devenir un athlète olympique.

Notre hypothèse est que les athlètes nés en début d'année (janvier, février, mars) sont surreprésentés. Dans les catégories de jeunes, ils sont physiquement plus matures de quelques mois que ceux nés en fin d'année, ce qui les place plus facilement dans les filières d'élite (le fameux "Relative Age Effect").

Pour vérifier cela, nous allons extraire le mois de naissance de chaque athlète et observer la distribution comparée à une répartition théorique parfaite (environ 8.33% par mois).

L'Effet d'Âge Relatif chez les athlètes olympiques


Distribution des mois de naissance comparée à une répartition uniforme



Interprétation : La ligne rouge représente la répartition théorique uniforme des naissances, soit environ 8,33 % des athlètes par mois. Les proportions observées sont globalement proches de cette valeur de référence, ce qui indique une répartition relativement homogène des mois de naissance parmi les athlètes olympiques. Bien que certains mois présentent des proportions légèrement supérieures ou inférieures à la moyenne théorique, les écarts restent faibles et aucune surreprésentation marquée des mois de début d'année n'apparaît clairement.

Dans quels sports cet effet est-il le plus marqué ? Pour aller plus loin, nous pouvons identifier les disciplines où ce phénomène est le plus prononcé. L'hypothèse est que les sports nécessitant une grande maturité physique précoce (puissance, vitesse, taille) afficheront un effet d'âge relatif plus fort que les sports de pure technique.

Nous allons calculer le pourcentage d'athlètes nés au premier trimestre (Janvier, Février, Mars) par sport. Théoriquement, si la naissance n'avait aucune influence, ce chiffre devrait être autour de **25%** (3 mois sur 12).




Interprétation : En filtrant les sports et en isolant la part d’athlètes nés dans le premier trimestre (Q1), le graphique met en évidence les disciplines où la date de naissance joue le rôle le plus crucial. La ligne rouge verticale représente l’espérance théorique (25%). Les sports qui s’en éloignent fortement vers la droite, comme le Patinage de Vitesse, la Lutte ou le Saut à ski, démontrent un “Relative Age Effect” très marqué. Dans ces sports physiques où les catégories d’âge dans l’enfance sont strictes, être né en tout début d’année offre un avantage physique temporaire décisif qui se transforme en un avantage de sélection durable menant jusqu’au plus haut niveau olympique.

TEMPORALITÉ : Évolution des JO

Question 18 : Combien d’athlètes participent aux Jeux Olympiques d’Été par rapport aux Jeux Olympiques d’Hiver ?

Hypothèse : Nous supposons que les Jeux Olympiques d’Été rassemblent un plus grand nombre d’athlètes que les Jeux Olympiques d’Hiver.

Cette différence s’explique par le nombre plus élevé de disciplines sportives présentes aux Jeux d’Été ainsi que par la participation d’un plus grand nombre de pays.



Choix du graphique Nous avons choisi un diagramme en barres car il permet de comparer facilement les effectifs de deux catégories distinctes : les Jeux d'Été et les Jeux d'Hiver.

Ce type de représentation rend immédiatement visible la différence d'envergure entre les deux compétitions.

Interprétation

En comparant les deux barres, on constate que les Jeux d'Été rassemblent nettement plus d'athlètes que les Jeux d'Hiver. Avec plus de 5 000 participants contre environ 3 300, les Jeux d'Été apparaissent comme la compétition la plus importante en termes de participation dans ce dataset. Cette différence s'explique probablement par la diversité plus importante des sports représentés lors des Jeux d'Été.


Question 19 : L'âge moyen des athlètes médaillés a-t-il augmenté ou diminué tout au long de l'histoire des Jeux Olympiques ?

Nous cherchons donc à regarder l'âge médian des médaillés dans les Jeux Olympiques, pour pouvoir comparer entre les années, pour voir si il y a des changements notables.

Notre hypothèse est que l'âge moyen pourrait augmenter en fonction de l'année, grâce aux avancements de la médecine et de la technologie, qui permettraient aux athlètes d'avoir une carrière plus longue, et de rester au maximum de leurs capacités pendant plus longtemps.

Pour cela nous allons donc faire un line chart, pour pouvoir avoir l'évolution, et une courbe de tendance globale, pour pouvoir voir une plus grande variété de résultats.

Moyenne par édition avec courbe de tendance globale (1896–2024)



Interprétation : On peut voir sur ce graphique, que notre hypothèse n'est pas validée. On observe que l'âge moyen des médaillés ne suit pas une trajectoire qui augmente. Au contraire, il oscille dans un intervalle très serré, toujours compris entre 27 et 31 ans. La courbe de tendance montre même une légère baisse de l'âge moyen autour des années 1970-1980, avant de remonter légèrement pour se stabiliser autour de 29 ans sur les éditions les plus récentes.

On peut donc en comprendre que les technologies et la médecine n'ont pas un effet assez fort pour influencer l'âge moyen des médaillés.

Question 20 : L'évolution morphologique temporelle (La spécialisation des corps)


Nous avons vu précédemment que l'IMC impacte la performance aujourd'hui. Mais est-ce que cette optimisation a toujours existé ? Les athlètes sont-ils devenus physiquement plus "extrêmes" au fil des décennies dans certaines disciplines ?

Notre hypothèse est qu'avec la professionnalisation du sport, le physique des athlètes s'est ultra-spécialisé. La taille moyenne des basketteurs a augmenté, tandis que celle des gymnastes a diminué par rapport aux premières éditions des Jeux Olympiques.

Pour valider cette hypothèse, nous croisons les variables d'année, de taille et de discipline pour deux sports aux besoins morphologiques opposés : le Basketball et la Gymnastique Artistique.

Évolution de la taille moyenne des athlètes (1896–2024)

Spécialisation morphologique opposée entre le Basketball et la Gymnastique



Interprétation

Ce graphique met en évidence une spécialisation morphologique entre les deux disciplines étudiées. Les basketteurs présentent une taille moyenne nettement plus élevée que les gymnastes, ce qui confirme que certaines caractéristiques physiques sont particulièrement avantageuses selon le sport pratiqué. On observe également une légère augmentation de la taille moyenne en basketball au fil du temps, tandis que celle des gymnastes tend à légèrement diminuer.


Il est important de noter qu'un important trou de données apparaît entre 1924 et 1996. Cela s'explique par le jeu de données utilisé : durant cette période, la base ne contient que des données des Jeux Olympiques d'Hiver, et aucune donnée des Jeux d'Été. Or, le Basketball et la Gymnastique Artistique étant des disciplines exclusivement disputées lors des Jeux d'Été, il est normal qu'aucune donnée n'apparaisse au centre du graphique.

Question 21 : Corrélation entre expérience olympique et succès

Existe-t-il un "pic d'efficacité" en fonction du nombre de participations (`total_olympics_attended`) ? Est-on plus susceptible de gagner l'or à sa 1ère, 2ème ou 3ème participation ?

Notre hypothèse est que la performance maximale survient plus souvent après plusieurs participations.

Pour répondre à cette question sans être biaisé par le fait qu'il y a beaucoup plus d'athlètes réalisant une seule participation par rapport à ceux en cumulant plusieurs, nous allons créer une Heatmap (Carte de chaleur). Elle affichera la proportion (en pourcentage) de chaque type de résultat selon le nombre de participations.



Interprétation : La carte de chaleur permet de visualiser de façon claire la probabilité d’obtenir une médaille (Or, Argent, Bronze) ou aucune selon l’expérience olympique de l’athlète. On remarque généralement que la proportion de “None” baisse à mesure que le nombre de participations augmente, ce qui indique que les athlètes plus expérimentés ont de meilleures chances globales de repartir avec une médaille.

Concernant l’Or spécifiquement, cette visualisation permet de confirmer légèrement l’hypothèse que les athlètes ont plus de chance d’avoir une médaille d’or après plusieurs participations.

Question 22 : Sports d’équipe vs Sports individuels : l’âge de l’or


Dans cette partie, nous cherchons à savoir si la dynamique d’équipe influe sur la longévité de la performance au plus haut niveau (la médaille d’or). L’âge de la performance maximale diffère-t-il selon que le sport se pratique seul ou en équipe ?

Notre hypothèse est que l’âge médian des médaillés d’or est plus élevé dans les sports d’équipe (Team). L’intelligence tactique, l’expérience et la cohésion de groupe permettent de compenser le léger déclin physique lié à l’âge, là où l’explosivité pure prime davantage dans les sports individuels (Individual).

Pour le vérifier, nous isolons tous les athlètes ayant remporté l’Or et comparons la distribution de leur âge selon la nature de leur épreuve (Individuelle ou Équipe).

Âge des médaillés d'or : Sports individuels vs Équipe

Comparaison de l'âge de la performance maximale



Interprétation : Le graphique va plutôt à l'encontre de notre hypothèse de départ, ce qui est un peu surprenant.


En regardant la médiane (la ligne noire épaisse au milieu de chaque boîte), on voit que l'âge médian des médaillés d'or est de 30 ans en individuel, contre 28 ans en équipe. C'est donc l'inverse de ce qu'on attendait : la médaille d'or arrive en moyenne un peu plus tard chez les individuels que chez les sports collectifs.

On peut tenter une explication : les sports individuels regroupent beaucoup de disciplines où la précision et la technique comptent autant que le physique (le tir, l'équitation, la voile...), ce qui autorise des carrières assez longues, alors que les sports d'équipe comme le football ou le basketball demandent un engagement athlétique plus intense et favorisent peut-être des vainqueurs un peu plus jeunes.

Cela dit, il faut rester prudent sur cet écart. Les deux boîtes se ressemblent énormément : l'essentiel des vainqueurs se situe entre 22 et 35 ans dans les deux cas, et si la médiane diffère de 2 ans, les moyennes, elles, sont quasiment identiques (environ 28 ans des deux côtés). On a aussi déjà constaté que l'âge est une variable peu marquée dans ce dataset. La différence est donc bien réelle sur le graphique, mais elle reste légère et à prendre avec précaution.

Question 23 : Les athlètes ayant la plus grande longévité sont-ils aussi ceux qui ont participé à la plus grande diversité d'épreuves ?

Hypothèse : On suppose que les athlètes les plus polyvalents, c'est-à-dire ceux qui participent à plusieurs sports ou épreuves, peuvent avoir une carrière plus longue.



Choix du graphique Nous avons choisi un nuage de points car il permet d'étudier la relation entre deux variables quantitatives : la longévité de carrière et le nombre d'épreuves différentes pratiquées. Chaque point représente un athlète.

Interprétation Ce graphique présente la relation entre la longévité de carrière des athlètes et le nombre d'épreuves différentes auxquelles ils ont participé. La majorité des observations se concentrent autour de 2 à 3 épreuves, quelle que soit la durée de la carrière. On n'observe pas de tendance clairement croissante indiquant que les athlètes ayant les carrières les plus longues participent à davantage d'épreuves. Bien que quelques athlètes cumulent une forte longévité et une plus grande diversité d'épreuves, ces cas restent isolés. Globalement, les résultats ne permettent pas de confirmer l'hypothèse selon laquelle la polyvalence favorise systématiquement une carrière plus longue. La durée de carrière semble donc relativement indépendante du nombre d'épreuves pratiquées dans ce dataset.

Conclusion Ce graphique permet de tester l'hypothèse selon laquelle la polyvalence favorise une carrière plus longue. Il met en relation la durée de carrière des athlètes avec leur diversité d'épreuves, afin de voir si les athlètes les plus polyvalents sont aussi ceux qui restent le plus longtemps dans les Jeux olympiques.

Annexe : Répartition des questions

Voici la répartition de la rédaction et de l'analyse des questions du rapport :

Simon Pereaux

- **Question 5** : Est-ce que la taille/poids d'un athlète influence sa performance ?
- **Question 11** : L'efficacité des délégations (Ratio Participation/Succès)
- **Question 17** : Le phénomène de l'Effet d'Âge Relatif (Relative Age Effect)
- **Question 20** : L'évolution morphologique temporelle (La spécialisation des corps)
- **Question 21** : Corrélation entre expérience olympique et succès

Lucas Gilbert

- **Question 4** : Existe-t-il une différence en terme de poids, entre les athlètes participant aux Jeux D'été, et ceux des Jeux d'hiver ?
- **Question 9** : Quels sont les pays qui ont accumulé le plus de médailles d'or au cours de l'histoire des Jeux Olympiques ?
- **Question 12** : Le pays hôte affiche-t-il une augmentation de son ratio de médailles par rapport à sa moyenne historique ?
- **Question 16** : Quelles sont les disciplines sportives qui comptent le plus grand nombre d'athlètes enregistrés ?
- **Question 19** : L'âge moyen des athlètes médaillés a-t-il augmenté ou diminué tout au long de l'histoire des Jeux Olympiques ?

Abdelmoughit OUDINA

- **Question 1** : Existe-t-il une corrélation visuelle entre la taille et le poids des athlètes, toutes disciplines confondues ?
- **Question 6** : La taille des athlètes influence-t-elle davantage les performances mesurées en distance (mètres) que celles mesurées en temps (secondes) ?
- **Question 7** : L'écart-type de la taille des athlètes au sein d'une même discipline a-t-il diminué entre 1924 et 2024 ?
- **Question 18** : Combien d'athlètes participent aux Jeux Olympiques d'Été par rapport aux Jeux Olympiques d'Hiver ?
- **Question 23** : Les athlètes ayant la plus grande longévité sont-ils aussi ceux qui ont participé à la plus grande diversité d'épreuves ?

ANALLA Ace

- **Question 2** : Chaque discipline possède-t-elle une « empreinte morphologique » qui lui est propre ?
- **Question 3** : Peut-on classer les disciplines selon un « gabarit type » mesuré par l'IMC ?
- **Question 10** : Quelles nations sont des « machines à or » et lesquelles sont des « collectionneuses de médailles » ?
- **Question 13** : L'ancienneté olympique et le rang historique d'une nation prédisent-ils son palmarès ?
- **Question 14** : Y a-t-il un genre plus représenté que l'autre ?
- **Question 22** : Sports d'équipe vs Sports individuels : l'âge de l'or

Application Shiny (Travail de groupe)

- **Question 8** : Application Shiny - un explorateur morphologique interactif